

电子科技大学  
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

# 专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 基于轻量化模型的实时森林山火检测  
技术研究

|        |              |
|--------|--------------|
| 专业学位类别 | 电子信息         |
| 学 号    | 202152060216 |
| 作者姓名   | 丁卓越          |
| 指导教师   | 周小佳 副教授      |
| 学 院    | 自动化工程学院      |

分类号 TP183 密级 公开  
UDC 注 1 614.8

# 学 位 论 文

## 基于轻量化模型的实时森林山火检测技术研究

(题名和副题名)

丁卓越

(作者姓名)

指导教师 周小佳 副教授  
电子科技大学 成 都  
(姓名、职称、单位名称)

申请学位级别 硕士 专业学位类别 电子信息  
提交论文日期 2024 年 4 月 15 日 论文答辩日期 2024 年 5 月 8 日  
学位授予单位和日期 电子科技大学 2024 年 6 月  
答辩委员会主席  
评阅人

注 1: 注明《国际十进分类法 UDC》的类号。

# **Research on real-time wildfire detection technology based on lightweight model**

A Master Thesis Submitted to  
University of Electronic Science and Technology of China

Discipline **Electronic Information**

Student ID **202152060216**

Author **Ding Zhuoyue**

Supervisor **A.Prof. Zhou Xiaojia**

School **School of Automation Engineering**

## 摘 要

森林山火是一种具有突发性和破坏性的自然灾害，会对环境和个人财产造成无法挽回的损失。为了最大限度地降低损失，在无人机上部署深度学习算法实现森林山火的实时检测，具有重要的研究意义。目前，基于深度学习的森林山火检测算法为了追求高精度的目的，使得网络的结构越来越复杂，导致参数量和计算量十分庞大，难以在无人机上部署，无法满足实时检测的需求。因此，设计轻量化 YOLO-LNet 模型，并通过模型压缩技术得到超轻量化 YOLO-ULNet 模型，将其部署在无人机中实现实时检测是本文的关键。本文的主要贡献如下：

1. 设计了轻量化模型 YOLO-LNet。该模型由输入、骨干网络、颈部网络和输出头组成。其中，骨干网络由组通道重排单元组成的轻量级特征提取模块构建而成，以提取目标特征图并减少参数量；颈部网络采用部分卷积组成的轻量级特征融合（LEF）单元和改进的 C3\_LEF 单元组成的多路径聚合的特征金字塔结构，以融合不同维度的特征图并减少计算量。最后，设计了归一化 Wasserstein 距离的标签分配策略和损失函数，提高小目标的检测准确性。在 COCO 数据集上对 YOLO-LNet 进行了验证，结果表明该模型的计算量和参数量分别为 0.7GFLOPs、0.26M，mAP@0.5 为 37.2%，优于主流的轻量级 SOTA 算法 YOLOv5-Lite 的 35.1%，且只有 YOLOv5-Lite 参数量的 39.7%。此外，在无人机上使用 Fire-Smoke 数据集对 YOLO-LNet 进行了测试，结果表明该模型的检测精度和速度分别为 77.75%和 14.39FPS，仍无法满足实时（20FPS）检测要求。

2. 研究并设计了超轻量化模型 YOLO-ULNet。针对 YOLO-LNet 实时性不足的问题，设计了超轻量化 YOLO-ULNet 模型。在通道剪枝方面，主要采用在 BN 层中施加  $L_1$  正则化方法筛选模型中的冗余通道，以提高检测速度。在特征蒸馏方面，主要采用归一化特征蒸馏方式对齐中间层特征，将教师网络 YOLO-LNet 中的特征传递到学生网络 YOLO-ULNet，以提高检测精度。量化方法则将权重为 32 位的浮点数转化为 8 位整数，进一步提高了检测速度。在无人机上使用 Fire-Smoke 数据集对 YOLO-ULNet 进行了测试，该模型的检测精度和速度分别为 74.50%和 24.57FPS，满足了实时性的要求。

综上所述，本文设计的 YOLO-ULNet 能够部署在无人机上实现森林山火的实时检测，具有重要的现实意义。

**关键词：**无人机，通道剪枝，特征蒸馏，量化，实时检测，超轻量化模型

## ABSTRACT

Wildfires are paroxysmal and destructive natural disasters, which can cause irreparable damage to the environment and personal property. In order to minimise the losses, deploying deep learning algorithms on UAVs to achieve real-time detection of forest hill fires is of great research significance. Currently, deep learning-based wildfire detection algorithms make the structure of the network more and more complex in order to achieve high accuracy, resulting in a very large number of parameters and computation, which makes it difficult to be deployed on UAVs and fails to meet the demand for real-time detection. Therefore, designing a lightweight YOLO-LNet model and obtaining an ultra-lightweight YOLO-ULNet model by model compression technique, and deploying it in UAVs to achieve real-time detection is the key of thesis. The main contributions of thesis are as follows:

1. The lightweight model YOLO-LNet was designed. The model consists of input, backbone network, neck network and output header. Among them, the backbone network is constructed by a lightweight feature extraction module composed of group channel rearrangement units to extract the target feature maps and reduce the number of parameters; the neck network adopts a feature pyramid structure with multi-path aggregation composed of a lightweight feature fusion (LEF) unit with partial convolution and an improved C3\_LEF unit to fuse feature maps in different dimensions and reduce the amount of computation. Finally, a label assignment strategy and loss function for normalised Wasserstein distance are designed to improve the detection accuracy of small targets. YOLO-LNet is validated on the COCO dataset, and the results show that the computational and parametric quantities of the model are 0.7GFLOPs, 0.26M, mAP@0.5 is 37.2% respectively, which are better than 35.1% of the mainstream lightweight SOTA algorithm YOLOv5-Lite and only 39.7% of the parametric quantity of YOLOv5-Lite. In addition, YOLO-LNet was tested on a UAV using the Fire-Smoke dataset, and the results show that the detection accuracy and speed of the model are 77.75% and 14.39FPS, respectively, which still cannot meet the real-time detection requirements.

2. The ultra-lightweight model YOLO-ULNet was studied to address the real-time performance issues of YOLO-LNet. In terms of channel pruning, the redundant

channels in the model are mainly screened by applying  $L_1$  regularisation in the BN layer to improve the detection speed. In terms of feature distillation, normalised feature distillation is mainly used for its middle layer features to pass features from the teacher network YOLO-LNet to the student network YOLO-ULNet to improve the detection accuracy. The quantisation method further improves the detection speed by converting floating point numbers with 32-bit weights into 8-bit integers. The YOLO-ULNet was tested on a UAV using the Fire-Smoke dataset, and the detection accuracy and speed of the model were 74.50% and 24.57 FPS, respectively, which met the real-time requirements.

In summary, the designed YOLO-ULNet can be deployed on drones to achieve real-time detection of forest wildfires, which holds significant practical implications.

**Keywords:** UAVs, Channel pruning, feature distillation, quantisation, real-time detection, ultra-lightweight models

# 目 录

|                                   |    |
|-----------------------------------|----|
| 第一章 绪论.....                       | 1  |
| 1.1 研究背景及意义.....                  | 1  |
| 1.2 国内外研究现状.....                  | 3  |
| 1.2.1 数字图像处理技术检测森林山火的研究现状 .....   | 4  |
| 1.2.2 深度学习算法检测森林山火的研究现状 .....     | 5  |
| 1.2.3 基于轻量化模型检测森林山火的研究现状 .....    | 7  |
| 1.3 论文的主要研究内容和创新点 .....           | 8  |
| 1.4 本文结构安排.....                   | 9  |
| 第二章 轻量化模型检测原理分析 .....             | 12 |
| 2.1 引言.....                       | 12 |
| 2.2 YOLO 技术.....                  | 12 |
| 2.2.1 YOLO 原理.....                | 12 |
| 2.2.2 YOLO 基本结构.....              | 14 |
| 2.3 轻量化技术.....                    | 16 |
| 2.3.1 通道剪枝技术.....                 | 16 |
| 2.3.2 特征蒸馏技术.....                 | 18 |
| 2.3.3 模型量化技术.....                 | 19 |
| 2.4 性能指标.....                     | 21 |
| 2.5 数据集介绍.....                    | 22 |
| 2.6 本章小结.....                     | 23 |
| 第三章 轻量化 YOLO-LNet 模型的设计与验证.....   | 24 |
| 3.1 引言.....                       | 24 |
| 3.2 轻量化 YOLO-LNet 模型的设计 .....     | 24 |
| 3.2.1 骨干网络的设计 .....               | 24 |
| 3.2.2 颈部网络的设计 .....               | 28 |
| 3.2.3 标签分配策略和损失函数的设计 .....        | 31 |
| 3.2.4 YOLO-LNet 模型的构建 .....       | 33 |
| 3.3 轻量化 YOLO-LNet 模型的验证.....      | 34 |
| 3.3.1 数据集的预处理.....                | 34 |
| 3.3.2 实验环境和超参数配置.....             | 42 |
| 3.3.3 消融实验.....                   | 43 |
| 3.3.4 对比实验.....                   | 44 |
| 3.4 本章小结.....                     | 52 |
| 第四章 超轻量化 YOLO-ULNet 模型的设计与验证..... | 54 |

|                                |    |
|--------------------------------|----|
| 4.1 引言.....                    | 54 |
| 4.2 超轻量化 YOLO-ULNet 模型的设计..... | 54 |
| 4.2.1 改进的通道剪枝技术.....           | 54 |
| 4.2.2 改进的特征蒸馏技术.....           | 57 |
| 4.3 超轻量化 YOLO-ULNet 模型的验证..... | 61 |
| 4.4 超轻量化 YOLO-ULNet 模型的部署..... | 63 |
| 4.4.1 int8 量化.....             | 63 |
| 4.4.2 模型部署.....                | 65 |
| 4.5 本章小结.....                  | 67 |
| 第五章 总结与展望.....                 | 69 |
| 5.1 研究工作总结.....                | 69 |
| 5.2 展望.....                    | 70 |
| 参考文献.....                      | 71 |



第一章 绪论

1.1 研究背景及意义

森林在国民经济中扮演着重要的角色，它不仅为国家建设和人民生活提供所需的木材及林副产品，同时也担负着释放氧气、调节气候、涵养水源、保持水土、防风固沙等多种使命。然而，森林山火的发生会给人民生活带来严重危害，它不仅会给生态环境造成破坏，而且还会威胁到人民生命财产安全。

每年春秋两季是我国森林山火发生的高峰期，主要原因是在较为干燥的环境下，森林中有机物质会挥发出大量可燃气体，与充足的氧气结合，容易产生山火。一旦发生山火，森林中植被茂密，可燃物充足，给火灾蔓延提供有利条件。由于森林山火具有发生面广、突发性强、破坏性大的特点，所以给我国人民生命安全和经济带来了极大威胁。

如表 1-1 所示是近五年我国森林山火统计情况。由表可知，2020 年，我国共发生森林山火 1153 起，破坏森林面积达 8526 公顷，造成 41 人伤亡，累计折合损失 10077.7 万元。2021 年，我国共发生森林山火 616 起，破坏森林面积达 4457 公顷，造成 28 人伤亡，直接损失达到 3324.1 万元。2022 年，我国共发生森林山火 709 起，破坏森林面积达 6854 公顷，造成 44 人伤亡，累计折合损失 38845.6 万元。2023 年，云南省玉溪市江川区九溪镇河口村附近发生重大山火，云南省消防救援总队历时 4 天，投入 1020 人 130 车参与玉溪江川森林火灾扑救工作，最终全部扑灭。2024 年 3 月 15 日，四川省甘孜州雅江县呷拉镇白孜村突发森林火灾，受火情影响共计 11 个村 1 个社区 837 户 3396 人，累计投入扑救力量 2326 人。2024 年 3 月 16 日，云南省临沧市临翔区圈内乡斗阁村森林发生火灾，过火面积约 5.33 公顷，有 3 名地方扑火人员不幸遇难，另有 1 人受伤。

由此可知，森林山火发生的危害程度和伤亡人数呈现出上升的趋势。因此，为了最大限度地降低森林山火对环境的破坏和个人财产的损失，及时有效地进行森林山火检测，具有重要的研究意义。

表 1-1 2018-2022 年森林山火统计表

| 年份         | 2018    | 2019    | 2020    | 2021   | 2022    |
|------------|---------|---------|---------|--------|---------|
| 森林山火次数     | 2478    | 2345    | 1153    | 616    | 709     |
| 火场总面积（公顷）  | 28595   | 39705   | 25081   | 14124  | 28285   |
| 受害森林面积（公顷） | 16309   | 13505   | 8526    | 4457   | 6854    |
| 伤亡人数（人）    | 39      | 76      | 41      | 28     | 44      |
| 其它损失折合（万元） | 20444.7 | 16219.9 | 10077.7 | 3324.1 | 38845.6 |

目前，常见的森林山火检测方法主要有多传感器技术<sup>[1-5]</sup>、卫星遥感技术<sup>[6-10]</sup>和无人机山火检测技术<sup>[11-15]</sup>。其中，多传感器技术利用分布在森林中的传感器来采集山火产生的烟雾等环境数据，并借助通信链路将环境数据传给后台进行山火的判别。由于单个传感器覆盖范围有限，而布设大量传感器导致成本高，使得其应用受到了一定程度的限制。此外，海量数据传输会堵塞通信链路，导致传输延迟，实时性不好。卫星遥感技术则通过卫星监测火灾周围环境的变化识别山火的发生，可避免多传感器检测范围的局限性。然而，该技术由于自身运行周期长，难以对山火进行及时检测，不利于山火的迅速扑灭。无人机山火检测技术<sup>[16-20]</sup>则利用无人机采集森林图像数据并传输至服务器端，利用服务器端的深度学习算法实现森林山火的检测，如图 1-1 所示是无人机山火检测技术的原理示意图。与多传感器技术和卫星遥感技术相比，无人机山火检测技术具有灵活性好、速度快等优点，可在短时间内对大面积的森林区域进行检测，是目前国内外的研究热点。

在服务器端部署深度学习算法对森林山火进行检测具有准确率高、鲁棒性强等优点，但会带来繁琐的计算量和参数量，使得在算力受限的无人机上部署深度学习算法直接对森林山火进行实时检测面临着巨大的挑战。



图 1-1 无人机山火检测技术的原理示意图

为了在无人机中部署轻量化模型以实现森林山火的实时检测，本文对基于轻量化模型的实时森林山火检测技术展开了研究，其主要内容如下：

#### (1) 研究轻量化 YOLO-LNet 模型

针对深度学习算法无法部署在算力低下的无人机上的难题，研究了轻量化 YOLO-LNet 模型用于检测森林山火。该模型主要由输入、骨干网络、颈部网络和输出头组成。其中，骨干网络作为特征提取器，由大量尺寸不等的卷积核、过滤

器以及多个分支构成,使其结构复杂,从而导致网络的参数量多。颈部网络用于融合不同尺度的特征,通常由密集计算的残差块形成的特征金字塔网络构建得到的,使其计算复杂度高,从而导致网络的计算量大。因此,设计参数量少,计算复杂度低,且特征提取能力强的轻量化模型具有重要意义,这将对无人机的部署至关重要。

## (2) 研究超轻量化 YOLO-ULNet 模型

针对 YOLO-LNet 实时性不足的问题,基于通道剪枝、特征蒸馏和量化等模型压缩技术,研究了超轻量化 YOLO-ULNet 模型。其中,针对 YOLO-LNet 模型中存在冗余通道导致检测速度慢的问题,研究了基于通道剪枝技术。针对剪枝后的模型检测准确性低的问题,研究了基于特征蒸馏技术。因此,研究具有更高性能的超轻量化 YOLO-ULNet 模型,是成功在无人机上实现实时检测的关键。

由以上分析可知,研究轻量化 YOLO-LNet 模型,减少 YOLO-LNet 的参数量和计算量。以及研究超轻量化 YOLO-ULNet 模型,提高 YOLO-ULNet 的检测速度和检测精度是目前基于轻量化模型的实时森林山火检测技术研究中的关键。因此,本文对基于轻量化模型的实时森林山火检测技术展开了深入研究,主要包括:轻量化模型检测原理分析;轻量化 YOLO-LNet 模型的设计与验证;超轻量化 YOLO-ULNet 模型的设计与验证。

## 1.2 国内外研究现状

森林山火作为一种严重的自然灾害,它不仅给人类带来巨大的经济损失,而且还会威胁到人民生命安全。据统计,全球每年平均发生森林火灾次数约 20 万次,所造成的灾难损失难以估量。正是由于其巨大的危害性,使得森林山火检测问题一直以来都是研究的热点。因此,许多专家学者提出了大量森林山火检测技术来解决这个问题,如基于多传感器融合的检测技术、基于卫星遥感的检测技术和基于计算机视觉的检测技术。其中,基于计算机视觉的检测技术最具吸引力,目前已成为研究森林山火检测领域的焦点。为了理清基于计算机视觉的检测技术不同方法之间的关系,本章将基于计算机视觉的检测技术划分为基于传统的数字图像处理方法和基于深度学习的方法。其中,基于深度学习的森林山火检测方法又可以划分为基于 R-CNN 系列的森林山火检测法<sup>[21-23]</sup>和基于 YOLO 系列的森林山火检测法<sup>[24-26]</sup>,以及基于轻量化模型的森林山火检测法。本节分别对这些方法进行了归纳分类,并对不同方法的优点和缺点进行了对比、分析和讨论。最后,对森林山火检测技术未来的发展方向、存在问题和挑战进行展望。

### 1.2.1 数字图像处理技术检测森林山火的研究现状

数字图像处理方法主要是从图像中提取火焰的色彩特征、纹理特征或几何形状,并结合烟雾轨迹来进行火灾辨识。其中,颜色特征最为常用。然而,在背景复杂、光照条件变化大、植被遮挡烟雾或火焰以及火焰和烟雾动态变化情况下会出现误检和漏检的情况,使得这种方法的检测效果不佳。为了克服单一特征辨识的局限性,一些研究人员采用了多种特征相结合的方式,将颜色、纹理和形状等多种特征结合起来,以提高检测精度。

早期在使用数字图像处理技术检测森林山火的过程中, Thou-Ho 等人<sup>[27]</sup>提出了一种基于视频处理的早期火灾预警方法,其基本思想是采用基于 RGB 的色彩模型和无序度测量来提取火焰和烟雾的像素特征,通过生长和无序动态以及结合烟雾特征,验证提取到的火焰像素是否为真火,以提高对火焰的识别精度。实验结果表明,该方法响应时间仅为 56s,可实现对火灾状况的全自动监控。这种仅仅使用色彩特征识别火焰的方法,准确度较低且效率低下。

为了弥补使用单一色彩信息所造成的识别不准确的问题。2015 年, Yuan 等人<sup>[28]</sup>提出了一种基于无人机的林火探测与跟踪方法。该系统的前端主要是使用无人机采集火灾图像信息,然后将图像数据传输至后端地面控制中心进行图像处理,其中的数字图像处理方法包括中值滤波、色彩空间转换、大津阈值分割、形态学运算和 Blob 计数器等。实验测试结果表明,使用实验室色彩模型的“a”通道检测森林火灾可以取得不错的结果。为了解决复杂场景中烟雾检测率低的问题。2018 年, Mahmoud 等人<sup>[29]</sup>提出了一种森林火灾检测算法。首先,对包含移动区域使用背景减法(MRDB)进行消除。其次,将分割的移动区域从 RGB 转换到 YCbCr 色彩空间,并应用五种火灾检测规则来分离候选火灾像素。最后,利用时间变化来区分火和与火颜色相似的物体。实验结果显示,所提出方法的真实检测率高达 96.63%。这表明,所提出的方法是准确的,可用于森林火灾自动预警系统。为了提高烟雾识别的准确率和降低误报率。2019 年, Li 等人<sup>[30]</sup>首先提出基于置信度水平的局部三值模式(CLLTP),进而提出了基于 CLLTP 的组合特征模型(M\_CLLTP)。CLLTP 是依据差分图像的像素值呈正态分布而提出的一种改进的局部三值模式。M\_CLLTP 模型提取了原图的 CLLTP 特征、Gabor 特征图的加权的 CLLTP 特征和边缘特征图的 CLLTP 特征,并融合他们生成 M\_CLLTP 特征。对比实验显示, M\_CLLTP 方法在三个烟雾数据集上获得了 97.5%的平均检测率、97.2%的平均 F1 得分和 0.96%的平均误报率,在两个烟雾边缘纹理数据库上分别获得了 97%和 80.07%的平均召回率。实验结果表明,所提出的方法对烟雾边缘的识别表现出良好的能力,非常适用于烟雾识别。为了进一步降低森林火灾识别中

的漏检和误检等问题。2020 年, Wei 等人<sup>[31]</sup>提出了一种基于 K-Means 聚类的样本熵判别算法。该算法首先将采集到的森林火灾图像进行色域空间转换, 然后采用 K-Means 聚类算法, 通过 HSV 分量的欧式距离准则, 对火灾预期出现的图像子集进行聚类。在此基础上, 通过样本熵对聚类后的图像子集权重进行辨别, 通过统计熵值差异来区分类火灾区域和火灾区域, 然后确认聚类筛选出来的图像子集是否存在火灾。最终实验表明该方法将火灾区域的识别正确率提高到 96.67%, 平均识别时间为 16.03s。为了进一步提高火灾探测算法的识别效率。2023 年, Giwa 等人<sup>[32]</sup>提出了一种新的基于火焰的色彩空间, 为了突出火焰与非火焰像素值之间的差异。采用了人工蜂群算法, 即一种基于学习的混合优化算法 (ABC-TLBO) 和 k-medoids 聚类算法相结合的算法, 计算出优化的色彩空间转换矩阵。然后, 使用二进制阈值法分离火灾像素和非火灾像素。实验结果表明, 所提出的基于火焰的色彩空间方法与最先进的色彩模型相比, F1 分数提高了 20%, 可以在火灾检测率和误报率之间取得更好的平衡。另外, 火灾探测系统的计算时间平均缩短了 15.6%。

基于传统的数字图像处理方法虽然具有计算简单、可解释性强等优点, 但是这种方法对于背景复杂、光照多变等条件表现不佳, 对噪声和遮挡敏感。此外, 传统的数字图像处理方法通常依赖于人工设计的特征进行检测, 对于不同场景需要重新设计特征, 缺乏通用性。因此, 国内外学者将目光投向了以深度学习为核心的计算机视觉技术。

### 1.2.2 深度学习算法检测森林山火的研究现状

由于深度学习方法可以通过大量的数据学习目标特征, 并通过不断优化模型, 实现高精度的预测和分类; 其次, 深度学习方法可以通过不断地学习和调整参数, 实现对不同场景的自适应, 以处理复杂的数据结构和非线性问题。另一方面, 深度学习方法可以通过增加层数和节点数, 实现对复杂问题的解决, 同时也可以通过分布式计算和 GPU 加速等技术, 实现高效的计算。

目前基于深度学习的森林山火检测方法可分为基于 R-CNN 系列的森林山火检测方法和基于 YOLO 系列的森林山火检测方法。

#### 基于 R-CNN 系列的森林山火检测方法

R-CNN 系列的目标检测算法属于典型的两阶段法, 所谓的两阶段法就是将检测问题分为两个阶段, 第一个阶段是产生候选区域, 包含目标的大概位置信息, 然后第二个阶段是对候选区域进行分类和位置精细调整, 该方法的最大优势是准确度高。

2019 年, Barmpoutis 等人<sup>[33]</sup>提出了一种深度学习与高阶线性动态系统结合的多维纹理火灾检测方法。该方法的首选火灾区域是一个经过训练的用于火灾检测任务的 Faster R-CNN 网络完成, 然后将候选的火灾区域投影到 Grassmannian 空间, 使得每个图像被表示为流形上的一组点云。最后, 应用矢量表示方法将流形上的点云聚合到 Grassmannian 空间上。经测试表明, 本文提出的方法应用于基于使用 AlexNet、VGG16 和 ResNet101 的 Faster R-CNN 架构, F-score 得分分别达到了 95.5%、99.6%和 99.7%。虽然 Barmpoutis 等人提出的检测方法对火灾检测可以达到非常高的精度。但对于小目标检测来说仍然具有挑战性, 由于小目标森林山火形状不规则、尺度不一且容易被障碍物遮挡, 其探测精度仍不理想。2023 年, Zhang 等人<sup>[34]</sup>通过改进 Faster R-CNN 目标检测模型, 提出了一种用于小目标森林火灾检测的多尺度特征提取模型 (MS-FRCNN)。具体来说, 在 MS-FRCNN 模型中, 使用 ResNet50 代替 VGG-16 作为该模型的骨干网络, 以减轻 VGG-16 在特征提取时的梯度爆炸或梯度消失的现象。在颈部网络中使用多尺度特征金字塔结构提高 MS-FRCNN 获取详细特征信息的能力。同时在区域建议网络 (RPN) 中使用了新的注意力模块, 通过将通道注意力和空间注意力并行操作, 降低图像中复杂背景的影响, 从而使 RPN 更加关注小目标林火的语义和位置信息。此外还采用了 soft-NMS 算法代替 NMS 算法, 以减少检测帧的误删。实验结果表明, 与基准模型 Faster R-CNN 模型相比, 所提出的 MS-FRCNN 对小目标森林火灾的检测性能更好, 其检测精度比基线模型高 5.7%, 达到了 85.2%。

#### 基于 YOLO 系列的森林山火检测方法

尽管基于 R-CNN 的森林山火检测方法具有检测精度高的优点, 但其检测过程中需要先找出感兴趣区域, 然后在检测出来, 这样的结果明显是以牺牲时间的代价换来的; 另一方面这种方法存在着模型庞大、计算复杂度高、参数量大等固有缺陷, 导致其在实际森林山火场景中工作时, 推理速度慢, 无法实现实时检测。因此, 在之后的工作中研究人员提出了基于 YOLO 系列的森林山火检测方法。

2023 年, Li 等人<sup>[35]</sup>在 YOLOv5 框架的基础上提出了一种新型轻量级检测模型 LEF-YOLO。为了使模型检测速度更快, 引入了 MobileNetV3 的瓶颈结构, 并使用深度可分离卷积代替传统卷积。为了提高模型的检测精度, 采用了多尺度特征融合策略, 并使用“坐标注意力机制”和“快速空间金字塔池化”块来增强特征提取能力。在构建的野火数据集上测得, LEF-YOLO 模型的计算量仅为 2.7GFLOPs、61FPS 和 mAP 为 87.9%。为了进一步提升火灾响应的及时性。2023 年, Al-Smadi 等人<sup>[36]</sup>针对烟雾散布的不规则性和周围环境的动态性, 以及烟雾识别中因像素的微小特征而变得复杂等要素来改进 YOLOv5x 模型检测森林烟雾。

最终，在近距离、中距离和远距离三个不同的检测区域数据集上验证模型。在 PC 端，YOLOv5x 模型的 mAP@0.5 为 96.8%，检测速度达到 122 帧/秒。

利用深度学习算法检测森林山火是当前学术界主流的方向。如本节中综述的两个技术路线，一种是基于 R-CNN 系列的森林山火检测方法，另一种是基于 YOLO 系列的森林山火检测方法。R-CNN 系列由于检测步骤复杂，因而准确率高，但检测速度缓慢；而 YOLO 系列检测步骤简单，速度较快，但是却损失了精度。使得精度和速度都无法达到平衡，且这些模型参数量大，模型复杂，难以在嵌入式设备上部署。因此，许多研究学者提出基于轻量化模型检测森林山火技术。

### 1.2.3 基于轻量化模型检测森林山火的研究现状

尽管 R-CNN 系列的森林山火检测模型精度高、YOLO 系列的森林山火检测模型在电脑端的检测速度快，但这些都是建立在强大的 GPU 基础上的。一旦将这些模型部署到低算力的嵌入式设备上，其复杂的计算量、众多的参数以及多变的结构会严重制约着模型的检测速度，甚至出现内存爆炸的情况发生。为了克服这一问题，近年来研究人员逐渐将目光投向了轻量化模型检测森林山火这一方向。

2020 年，Zeng 等人<sup>[37]</sup>采用轻量级设计方法对 Refinedet 模型进行了改进，使参数量减少了 87.4%、FLOPs 下降了 97%，并在火焰烟雾数据集上进行测试，mAP 只损失了 0.4%。为了进一步压缩模型大小，还使用了通道剪枝方法。剪枝后，参数量下降了 47.5%，FLOPs 下降了 43.0%，但 mAP 值却增加了 0.7%。为了减少参数和计算量，2021 年，Wang 等人<sup>[38]</sup>提出了一种轻量级的 YOLO 森林火灾检测模型。该模型使用轻量级 MobileNetV3 替换 YOLOv4 的主干网络。最终实验表明，与 YOLOv4 相比，本文所提出的模型参数减少了 62.78%，推理速度提高了 3.04 倍，检测精度达到了 66.6%。为了提高检测速度，2021 年，Fan 等人<sup>[39]</sup>提出了一种轻量级网络结构—YOLO-Light，用于森林火灾检测。具体来说，将原 YOLOv4 的主干特征提取网络用 MobileNet 代替，然后将路径聚合网络中的标准卷积替换为深度可分离卷积，从而提高了检测速度，使其更适合嵌入式设备。实验结果表明，与其他算法相比，YOLO-Light 的 mAP 达到了 75.72%，速度为 13.90 帧/秒，模型大小仅为 47.62MB。2023 年，Ye 等人<sup>[40]</sup>考虑到使用无人机部署深度学习图像处理技术，提出了基于 YOLOv5 的轻量化改进方法。首先，将主干网络替换为 ShuffleNetV2。然后，对主干网络和颈部网络进行剪枝。再对剪枝后的网络进行微调，以恢复检测精度。最后，通过硬件加速方法部署在树莓派 4B (RPi4B) 上。实验结果表明，该算法与其它最先进的算法相比，推理速度提高了

50%，达到了 9FPS，CPU 使用率和温度分别降低了 35%和 25%，功耗降低了 10%，而准确率仅降低了 2%。由于无人机终端设备的计算能力有限，在无人机上部署林火检测模型时，如何平衡精度和计算成本是一个难题。此外，无人机拍摄到的火灾目标较小，在检测过程中容易出现误检和漏检。2023 年，Xiao 等人<sup>[41]</sup>提出了一种针对小目标的轻量化模型 FL-YOLOv7。具体来说，设计了一个轻量级模块 C3Ghost 来代替 YOLOv7 中的特征提取块；并使用 Ghost 模块来替代骨干网络中的标准卷积层，加快推理速度和减少模型参数。其次，引入了无参数注意力机制，以突出烟火目标的特征并抑制背景干扰，在不增加网络参数的情况下提高模型的表示能力和泛化性能。最后，加入了自适应空间特征融合模块，以解决模型对小目标检测能力较弱的问题，并使用具有动态可调样本权重（WIoU）的损失函数来削弱低质量和复杂样本的影响，提高模型的整体性能。实验结果表明，与 YOLOv7 模型相比，FL-YOLOv7 模型的参数减少了 27%，同时小目标的 mAP50 提高了 2.9%，检测速度达到了 24.4 帧/秒。

尽管深度学习方法具有精度高、自适应性强以及可扩展性好的优点。但是其对数据的依赖性强，需要大量的数据来训练模型，数据质量和数据规模对算法的影响较大。另一方面，对于模型的内部运作机制缺乏可解释性，难以解释模型的预测结果，同时也难以排查模型中的错误和漏洞。最主要的原因是深度学习算法对计算资源要求高，需要大量的计算资源来训练模型，包括 CPU、GPU 和存储等资源，不利于在嵌入式设备上部署，无法满足实时检测的需求。

综合分析以上方法的优点和缺点，可以发现以无人机作为森林山火检测的载体有着十分优越的性能，而基于深度学习的森林山火检测算法具有检测精度高，泛化能力强和端到端学习等优点。但是，目前基于深度学习的森林山火检测算法计算复杂度高、参数量大，导致处理速度慢或无法直接部署在低算力的无人机上，这使得在无人机上部署轻量化模型实时检测森林山火研究迫在眉睫。因此，基于轻量化模型的实时森林山火检测技术研究具有十分重要的现实意义，故本论文以在无人机上部署轻量化森林山火检测算法为研究目标，并展开了深入研究。

### 1.3 论文的主要研究内容和创新点

本文以在无人机中部署轻量化模型实时检测森林山火为研究目标，研究了轻量化模型 YOLO-LNet，并对其性能进行了验证。针对 YOLO-LNet 无法在无人机中达到实时检测的要求，研究了通道剪枝、特征蒸馏和量化等模型压缩方法，研究了超轻量化模型 YOLO-ULNet，并成功将其部署在无人机中实现了森林山火的实时检测。本文的主要创新点与贡献如下：



### （1）设计了轻量化 YOLO-LNet 模型

针对深度学习算法无法部署在算力低下的无人机上的难题，研究了轻量化神经网络设计方法，并设计了 YOLO-LNet 模型用于检测森林山火。该模型主要由输入、骨干网络、颈部网络和输出头组成。首先，针对骨干网络结构复杂，参数量多的问题，构建了由组通道重排单元组成的轻量级特征提取模块，以提取目标特征图并减少参数量；随后，针对颈部网络高密度计算，计算任务繁重的问题，构建了由轻量级特征融合（LEF）单元和改进的 C3\_LEF 单元组成的多路径聚合的特征金字塔结构，以融合不同维度的特征图并减少计算量。最后，设计了归一化 Wasserstein 距离的标签分配策略和损失函数，提高小目标的检测准确性。在 COCO 数据集上对 YOLO-LNet 进行了验证，结果表明该模型的计算量和参数量分别为 0.7GFLOPs、0.26M，mAP@0.5 为 37.2%，优于主流的轻量级 SOTA 算法 YOLOv5-Lite 的 35.1%，且只有 YOLOv5-Lite 参数量的 39.7%。此外，在无人机上使用 Fire-Smoke 数据集对 YOLO-LNet 进行了测试，结果表明该模型的检测精度和速度分别为 77.75%和 14.39FPS，仍无法满足实时检测要求。

### （2）研究并设计了超轻量化 YOLO-ULNet 模型

针对 YOLO-LNet 实时性不足的问题，研究了基于通道剪枝、特征蒸馏和量化等模型压缩技术，设计了超轻量化模型 YOLO-ULNet。在通道剪枝方面，主要采用在 BN 层中施加  $L_1$  正则化方法筛选模型中的冗余通道，以提高检测速度。在特征蒸馏方面，主要采用归一化特征蒸馏方式对齐中间层特征，将教师网络 YOLO-LNet 中的特征传递到学生网络 YOLO-ULNet，以提高检测精度。量化法则将权重为 32 位的浮点数转化为 8 位整数，进一步提高了检测速度。在无人机上使用 Fire-Smoke 数据集对 YOLO-ULNet 进行了测试，该模型的检测精度和速度分别为 74.50%和 24.57FPS，满足了实时性的要求。

## 1.4 本文结构安排

根据研究内容合理划分，本文的结构安排如图 1-2 所示，具体如下：

### 第一章 绪论

首先阐述了选题的研究背景与意义，由此说明本文的研究方向具有重要的应用价值和研究意义。然后详细分析了国内外研究现状，从数字图像处理技术检测森林山火研究现状到基于深度学习算法检测森林山火的研究现状，再到基于轻量化模型检测森林山火的研究现状。最后，阐述了本文的主要创新点、贡献以及结构安排。

### 第二章 轻量化模型检测原理分析

首先介绍 YOLO 系列模型的原理和基本结构，分析了该模型框架的优越性。为下文设计轻量化森林山火检测模型奠定理论基础。接着详细介绍了深度学习模型压缩中的轻量化技术，如通道剪枝技术、特征蒸馏技术和模型量化技术，为模型压缩做理论支撑。



图 1-2 论文结构安排

### 第三章 轻量化 YOLO-LNet 模型的设计与验证

本章对轻量化 YOLO-LNet 模型的骨干网络和颈部网络进行了分析，并设计了轻量化 YOLO-LNet 模型。其中，详细介绍了轻量化 YOLO-LNet 模型的骨干网络和颈部网络的设计细节，以及介绍了各模块参数设置和采用这种结构的优势。最后，构建了 YOLO-LNet 模型的整体架构。在轻量化 YOLO-LNet 模型的验证部分，首先介绍了数据集的预处理、实验环境和超参数配置以及性能指标。然后，通过对比实验和消融实验验证轻量化模型 YOLO-LNet 的性能，为设计实时性好的超轻量化模型 YOLO-ULNet 奠定了坚实的基础。最后，对本章内容做了总结。

### 第四章 超轻量化 YOLO-ULNet 模型的设计和验证

本章对轻量化 YOLO-LNet 模型的模型压缩方法展开了研究。首先，采用通道剪枝方法对轻量化 YOLO-LNet 模型进行剪枝操作，剔除掉其中的冗余通道。然后，为了提高因通道剪枝产生的准确率下降问题，采用特征蒸馏方法提高轻量化 YOLO-LNet 模型的准确性。并通过实验验证了压缩后 YOLO-ULNet 模型的有效性。随后，为了进一步提高模型的检测速度，使用了模型量化方法对获得的超轻量化模型 YOLO-ULNet 进行部署，验证其在无人机上满足实时检测的目标。最后，对本章内容做了总结。

### 第五章 总结与展望

本章对本文的内容做了概括性的总结，并根据所做研究的不足之处，对后续工作做了进一步的展望。

## 第二章 轻量化模型检测原理分析

### 2.1 引言

本文的研究目标是在无人机中部署轻量化模型实时检测森林山火，以最大限度地减少人民生命财产安全和环境破坏。本章首先介绍了目标检测算法——YOLO 技术的原理和基本结构，并详细分析了该系列算法迭代的创新与不足。然后，介绍了轻量化技术相关理论知识，如通道剪枝技术、特征蒸馏技术和模型量化技术。最后，介绍了本文所使用的性能指标及数据集，作为下文验证轻量化 YOLO-LNet 模型性能的重要基础和依据。

### 2.2 YOLO 技术

YOLO 的全称是 You Only Look Once<sup>[42-47]</sup>，是在 CVPR 2016 中提出的一种目标检测算法，其核心思想是将目标检测问题视为回归问题，并利用单一的端到端网络完成从原始图像输入到物体位置和类别的输出。这种将“检测转化为回归问题”的思路十分高效，仅需一次便可完成整个训练过程。因此，在本文中设计轻量化森林山火检测算法将借鉴这种思想。

#### 2.2.1 YOLO 原理

YOLO 算法在前向传播过程中，直接利用全卷积神经网络对整个图像进行处理，并同时输出每个目标的预测类别和边界框位置信息。相比于传统的目标检测算法，YOLO 算法具有以下两个显著优势：

其一，速度快。由于 YOLO 算法的设计是将目标检测任务转化为回归问题，使得整体网络结构简单，仅需一次前向传播即可完成目标检测，因此速度非常快。其二，准确度高。YOLO 算法在损失函数的设计上采用了整体优化的方式，不仅考虑了物体位置和类别的预测准确度，还兼顾了边界框的定位准确度，从而整体上对目标的检测准确度较高。

对于 YOLO 算法的整体流程，将从以下几个方面具体解析：

##### （1）输入处理

给定一幅输入图像，首先将其划分成固定尺寸的网格。每个网格单元负责检测该单元内存在的目标。这种将整幅图像分解为多个网格的方式相当于是将目标检测任务分解为多个网格单元的目标定位和分类问题。

##### （2）特征提取

对于每个网格单元，使用一个预训练好的卷积神经网络来提取特征图。这些特征图可以直接用来预测目标的类别和位置。

### （3）目标预测

对于每个网格单元，该单元负责预测  $B$  个边界框，每个边界框包含了物体目标的位置和尺寸信息。此外，每个边界框预测对应目标的类别概率。

### （4）特征图解码

将预测的边界框位置信息和类别概率转换到原始图像坐标中。这一步骤通常使用逆变换技术（如相对坐标和绝对坐标的变换）来完成。

### （5）非极大值抑制

由于同一个目标可能会被多个网格单元预测到，为了避免重复预测，需要对预测结果进行非极大值抑制（Non-maximum Suppression, NMS）处理。NMS 通过设定阈值和交并比计算，筛选出最相关的目标边界框。

上文描述了 YOLO 算法的整体流程，下面将对整体流程中所涉及的关键技术进行说明：

#### 1. 网格划分与特征提取

YOLO 算法将输入图像划分为  $S \times S$  个网格单元。每个网格单元负责预测  $B$  个边界框。同时，对于每个边界框，预测得到  $C$  个类别概率。

为了准确地预测出目标，在卷积神经网络后面添加了一些额外的卷积层。这些额外的卷积层可以获得更加丰富和准确的特征。

#### 2. 边界框预测

对于每个网格单元，预测得到  $B$  个边界框，每个边界框由以下三个元素构成。①边界框的中心点相对于该网格单元左上角的偏移量坐标( $x, y$ )；②边界框的宽度和高度相对于整个图像的比例，即( $w, h$ )；③边界框包含目标的置信度得分，即 Confidence score。

对于每个边界框，使用 Sigmoid 函数将最后一层的输出映射到  $[0, 1]$  范围内以预测对应的类别概率。

#### 3. 特征图解码

对于预测的边界框位置信息，需要使用坐标变换（相对坐标和绝对坐标）进行特征图解码，将其转换到原始图像坐标中。

相对坐标是使用 Sigmoid 函数对预测的中心点相对于网格单元左上角的偏移量进行映射。然后将映射结果与网格单元的纵横比相乘，获得在原图像中的中心点坐标。而绝对坐标是使用指数函数对预测的边界框根据置信度进行排序。然后将映射结果与预设的锚框尺寸相乘，获得原图像中边界框的高度和宽度。

#### 4. 非极大值抑制

由于同一个目标可能被多个网格单元预测到，为了避免重复检测，在最后一步进行了非极大值抑制（NMS）处理。NMS 的目标是筛选出置信度最高的边界框，并且将与其相似度（即 IoU）较高的边界框丢弃。具体来说，首先，对预测的所有边界框按置信度进行排序。然后，从具有最高置信度的边界框开始，计算其与后续边界框之间的 IoU 值，并舍弃 IoU 值大于设定阈值的边界框，直到所有边界框被处理完毕。

非极大值抑制的过程可以减少冗余的边界框，使得最终的目标检测结果更精确。

### 2.2.2 YOLO 基本结构

YOLO 模型的基本结构主要由四个部件组成，如图 2-1 所示：

- 1) 输入：将输入的图像使用图像增强、归一化方法统一为标准尺寸进行训练和推理。
- 2) 骨干网络：对输入图像进行特征提取以获取不同维度的细粒度特征。
- 3) 颈部网络：对骨干网络提取的特征图进行融合，得到高维语义信息。
- 4) 输出头：对图像特征进行预测，生成边界框并预测类别。




图 2-1 YOLO 基本结构图

YOLO 系列的模型已经从 v1 发展到 v8，为了理清各版本之间的发展路线，对 YOLO 系列中具有指导性意义的模型加以具体说明，如 YOLOv3、YOLOv4、YOLOv5、YOLOv7。

在骨干网络的演变过程中，YOLO 系列模型一直沿用 DarkNet 网络，不同模型的骨干网络之间最大的不同是所选用的网络层数不同。这是一种使用大量小卷积核（1\*1 卷积核和 3\*3 卷积核）的网络，它的灵感来源于 Network in Network，其主要作用是减少参数数量。

在 YOLO 系列的颈部网络演变中，最经典的结构是特征金字塔结构，如图 2-2 所示。特征金字塔结构是一种具有自底向上和自顶向下两条路径的结构，自底向上的路径是卷积网络进行前向计算时得到的一个由多个尺度的特征图组成的多

层次特征结构；自顶向下的路径是对来自更高层级的金字塔进行上采样，得到在空间上更粗糙但语义上更强的特征图，从而产生更高分辨率的特征。伴随着特征金字塔结构的发展，也产生了图像特征金字塔结构、单尺度特征图金字塔结构、金字塔特征层次结构以及多路径聚合的特征金字塔结构。




图 2-2 多路径特征聚合的金字塔结构

在检测头的演变中，具有划时代的改进是在 YOLOv3 中。将检测头分为 3 个分支，这 3 个分支分别下采样 32 倍、16 倍和 8 倍，分别预测大、中、小三种不同尺度的目标。由于 32 倍下采样每个点的感受野更大，所以用于预测大目标；8 倍下采样每个点的感受野最小，所以用于预测小目标。

YOLO 系列中的另一显著变化是 Loss 损失函数的演变，从最初的 MSE Loss 到之后的 IoU Loss，用来反映预测框与真实检测框的检测效果。而在使用 IoU Loss 之后又经历了 GIoU Loss、DIoU Loss、CIoU Loss 和 EIoU Loss 的变化。如果两者重合则  $Loss = 0$ ，IoU Loss 便不能反映预测框和真实检测框之间的距离大小，此时会出现梯度消失，无法进行学习训练。为了解决这一问题，GIoU Loss 可以解决上面 IoU Loss 对距离不敏感的问题，但是 GIoU Loss 存在训练过程中发散等问题。之后使用能够同时包含预测框和真实框的最小闭包区域的对角线距离的 DIoU Loss，可以直接最小化两个目标框的距离，且比 GIoU Loss 收敛快得多。当两个框中心点重合时，中心点距离不变，DIoU Loss 不变，但宽高比会发生变化。因此增加了检测框的 Loss 和长和宽的 Loss。CIoU Loss 虽然考虑了边界框回归的重叠面积、中心点距离和宽高比，但是它未能有效地反映宽高比与置信度之

间的真实差异，这可能会阻碍模型在相似性优化方面的有效性。因此，提出了 EIoU Loss。

以上是 YOLO 系列模型中的经典结构以及相应的技术原理。由于本文的研究目标是基于轻量化模型的实时森林山火检测技术研究，而本文所设计的轻量化森林山火检测模型是在 YOLO 模型的基础上设计的。因此，有必要对 YOLO 系列模型的主要结构进行梳理，为后续模型设计奠定理论基础。

## 2.3 轻量化技术

由于大部分的深度神经网络计算复杂度高，参数量大，模型结构复杂多变，无法满足直接部署到无人机等嵌入式设备上，或无法满足对实时性要求高的场景。因此，在不严重影响模型性能的前提下对模型进行压缩加速，以减少网络的参数量和计算复杂度，提高运算能力，进而提升检测速度的目的。

### 2.3.1 通道剪枝技术

网络剪枝技术按照稀疏化程度的不同，被分为结构化剪枝和非结构化剪枝。

早期提出的连接权重稀疏化方法<sup>[48]</sup>是非结构化剪枝，这种方法能直接将模型压缩 10 倍以上，理论上可以减少 10 倍的计算量。但是，非结构化剪枝会带来计算特征上的“不规则”，对计算设备中的数据访问和大规模并行计算非常不友好，尤其对 GPU 硬件设备。这一缺陷的根本原因是非结构化剪枝主要通过对权重矩阵中的单个或整行、整列的权重值进行修剪。修剪后的新权重矩阵会变成稀疏矩阵（被修剪的值会设置为 0）。因而除非硬件平台和计算库能够支持高效的稀疏矩阵计算，否则剪枝后的模型是无法获得真正的性能提升。

因此，许多研究人员开始探索通过给神经网络剪枝添加一个“规则”用来约束剪枝，这种方法被称为结构化剪枝，使得剪枝后的稀疏方式更加适合并行硬件计算，“结构化剪枝”的基本修剪单元是卷积核或权重矩阵的一个或多个通道。由于结构化剪枝没有改变权重矩阵本身的稀疏程度，现有的计算平台和框架都可以对其实现很好的支持。而在结构化剪枝方法中，最具吸引力的方法是通道剪枝，主要是该方法可以有效地减少神经网络的参数量和计算量，从而提高模型的运算速度和效率。此外，该方法可以实现较为灵活的模型压缩，可以根据不同的任务需求进行调整。

本论文中的网络剪枝部分，使用的便是通道剪枝技术<sup>[49-51]</sup>。具体来说，对批正则化层（Batch Normalization, BN）中的缩放因子施加  $L_1$  正则化，然后对 BN 层的缩放因子不断调整，通过缩放因子不断趋于 0 来识别不重要的通道。通道剪



枝中对通道修剪所使用的损失函数如公式（2-1）所示。因为每个缩放因子只对应于特定的卷积通道（或全连接层中的神经元），这有助于在接下来的操作中对不重要的通道进行判别和修剪。

$$L = \sum_{(x,y)} l(f(x,W),y) + \lambda \sum_{\gamma \in \Gamma}^n g(\gamma) \quad (2-1)$$

其中  $(x,y)$  表示训练的输入和目标， $W$  表示可训练参数，公式中第一项表示 CNN 正常训练的损失项， $g(\cdot)$  是缩放因子上的稀疏性惩罚，具体选用的是  $L_1$  范数， $\lambda$  是平衡因子，也可以看作是对后一项进行了归一化。

图 2-3 是通道剪枝的原理示意图。设置的缩放因子（在 BN 层中重复使用）与卷积层中的每个通道串联。在训练过程中，对于这些缩放因子引入了稀疏正则化，使他们不断缩小，从而发现和修剪冗余通道。缩放因子值较小的通道（橙色）将被修剪（左侧）。剪枝后，获得了更加紧凑的模型（右侧），然后对修剪后的模型进行微调，以达到与完整网络相当甚至更高的精度。




图 2-3 通道剪枝原理示意图。(a)剪枝前，(b)剪枝后

通道剪枝的具体步骤如图 2-4 所示，核心主要是以下三步：

- (1) 计算每个卷积通道的重要性，一般是通过计算其输出的  $L_1$  范数或  $L_2$  范数来衡量。
- (2) 剔除掉重要性较低的通道，并重新学习网络。一般使用微调或重新训练来完成此过程。
- (3) 检验剪枝后的网络在测试集上的性能，如表现不佳，则回到步骤（1）重新进行剪枝。

重复上述过程，直到找到一个在性能和参数数量之间的理想平衡。




图 2-4 通道剪枝过程的流程图。虚线表示多通道/迭代方案。

### 2.3.2 特征蒸馏技术

知识蒸馏<sup>[52-54]</sup>的核心思想是用一个预训练的大模型去指导一个小模型的学习，最终，使小模型的效果可以逼近大模型的效果。在知识蒸馏中，按照知识的获取位置不同，如图 2-5 所示，知识蒸馏又可分为：基于响应的知识蒸馏，基于特征的知识蒸馏<sup>[52]</sup>，基于关系的知识蒸馏。




图 2-5 不同知识类别的直观示例图

深度神经网络善于学习不同层级的特征，因此中间层和输出层的都可以被用作知识来训练学生模型，对于最后一层的输出和中间层的输出（特征图），都是可以作为指导学生模型训练的知识，中间层的特征对于基于响应的知识蒸馏来说也是一个很好的补充，其主要思想是将教师和学生特征激活直接匹配起来。一般情况下，公式（2-2）基于特征的知识蒸馏中知识转移的蒸馏损失可表示为：

$$L_{FeaD}(f_t(x), f_s(x)) = L_F(\Phi_t(f_t(x)), \Phi_t(f_s(x))) \quad (2-2)$$

其中  $f_t(x)$ 、 $f_s(x)$  分别是教师模型和学生模型的中间层的特征图。变换函数  $\Phi(\bullet)$  只有当教师和学生模型的特征图大小不同时应用。 $L_F(\bullet)$  衡量的是两个特征

图之间的相似性，常用的有  $L_1$  正则化、 $L_2$  正则化、交叉熵等。图 2-6 是基于特征的知识蒸馏模型的通常架构。




图 2-6 基于特征的知识蒸馏模型的架构图

### 2.3.3 模型量化技术

模型量化<sup>[55]</sup>是将浮点运算转换为整型运算的一种模型压缩技术。实质上就是将模型中用 float32 表示的权重，量化为用 int8 表示，仅仅这一个操作，就可以获得 4 倍的空间压缩效果。

量化操作根据映射函数是否是线性的可以分为两类，即线性量化和非线性量化，本文主要研究线性量化技术。而根据 32 位浮点操作中数值的偏移量  $Z$  是否为 0 又可以将线性量化技术划分为对称量化和非对称量化，下面将对这两种技术原理做具体说明。

常见的线性量化过程可以用公式 (2-3) 的数学表达式来表示：

$$r = \text{Round}(S(q - Z)) \quad (2-3)$$

其中,  $q$  表示的是原始的 float32 数值;  $Z$  表示的是 float32 数值的偏移量;  $S$  表示的是 float32 的缩放因子;  $\text{Round}(\cdot)$  表示的是四舍五入近似取整数的函数, 除了四舍五入, 也可以使用向上或向下取整;  $r$  表示的是量化后的一个整数值。

### (1) 对称量化

如图 2-7 所示是对称量化的原理示意图。所谓的对称量化是通过一个映射公式将输入数据映射到 $[-128, 127]$ 的范围内, 图中 $-\max(|X_f|)$ 表示的是输入数据的最小值,  $\max(|X_f|)$ 表示输入数据的最大值。这个映射公式的关键是处理零点, 以确保原始输入数据中的零点在映射后仍对应 $[-128, 127]$ 区间的零点。在对称量化中, 需要求解出参数  $Z$  和缩放因子  $S$  来定义这种映射关系, 使得输入数据能够被有效地量化到指定的范围内。




图 2-7 对称量化的原理示意图

在使用对称量化中,  $r$  是用有符号的整型数值 (int8) 来表示的, 此时  $Z=0$ , 且  $q=0$  时恰好有  $r=0$ 。在对称量化中, 可以取  $Z=0$ ,  $S$  的取值可以使用公式 (2-4) 表示:

$$S = \frac{2^{n-1} - 1}{\max(|x|)} \quad (2-4)$$

其中,  $n$  被用来表示该数值的位宽,  $x$  是数据集的总体样本。

### (2) 非对称量化

如图 2-8 所示是非对称量化的原理示意图。所谓的非对称量化就是用一个映射公式将输入数据映射到 $[0, 255]$ 的范围内, 同样地, 图中  $\min(|X_f|)$ 表示的是输入数据的最小值,  $\max(|X_f|)$ 表示输入数据的最大值。总之, 对称量化通过映射关系将输入数据映射在 $[0, 255]$ 的范围内, 对于映射关系来说, 需求解出参数  $Z$  和  $S$ 。




图 2-8 非对称量化的原理示意图

在非对称量化中， $r$  是用有符号的整型数值（uint8）来表示的，此时取  $Z=\min(x)$ ， $S$  的取值可以使用公式（2-5）表示：

$$S = \frac{2^{n-1} - 1}{\max(x) - \min(x)} \quad (2-5)$$

其中， $n$  被用来表示该数值的位宽， $x$  是数据集的总体样本。

目前无论是移动端还是服务器端，都可以看到新的设备正在不断迎合量化技术。最新的统计数据表明，浮点 32 位操作的乘法运算的耗能是整型 8 位操作乘法运算的 18.5 倍，而芯片占用面积则是整型 8 位的 27.3 倍。在芯片设计和 FPGA 设计领域，更少的资源占用意味着能够设计出更多的计算单元；而更少的能耗则意味着更少的发热和更长的续航时间。因此，在本文中采用 int8 量化技术来优化部署于无人机上森林山火检测算法。

## 2.4 性能指标

在后续章节中评估模型的性能时，将采用以下指标来评估模型，通过这些指标可以客观准确的评价模型的性能。在本文研究中，使用类平均精度 mAP@0.5、检测速度 FPS、计算量（FLOPs）、模型参数量（Params）和模型大小这四个指标来评估模型的性能。

mAP@0.5 是一个评价多类别、多目标任务的定位和分类效果的综合性指标。mAP@0.5 是将 IOU 设置为 0.5 时，每个类别的平均精度的平均值；mAP@.5:0.95 是将 IOU 从 0.5 开始，每次间隔步长大小为 0.05，一直从 0.5 增至 0.95，计算每个类别的平均精度的平均值。mAP 的计算如公式(2-6)所示：

$$mAP = \frac{\sum_{i=1}^C AP_i}{C} \quad (2-6)$$

其中， $C$  表示类别总数， $AP_i$  表示第  $i$  类的  $AP$  值。而计算  $AP$  需要知道  $P$  和  $R$  的值，这三个指标的计算公式(2-7)、公式（2-8）、公式(2-9)所示：

$$P = \frac{TP}{TP + FP} \quad (2-7)$$

$$R = \frac{TP}{TP + FN} \quad (2-8)$$

$$AP = \int_0^1 P(R) dR \quad (2-9)$$

在公式(2-7)和公式(2-8)中， $TP$  表示输入的是正样本，预测结果也是正样本； $FP$  表示输入的是负样本，预测结果是正样本； $FN$  表示输入的是正样本，预测结

果是负样本。 $P$ 表示精确率，是针对预测结果而言的，它表示的是预测为正的样本中有多少是真正的正样本。 $R$ 为召回率，是针对原来的样本而言的，它表示的是样本中正例有多少被预测正确了。 $AP$ 则衡量了模型在单个类别上平均精度的好坏。其中， $P(R)$ 表示 $P$ 是 $R$ 在不同置信水平下的函数。 $AP$ 值越高，模型的性能越好。

IoU 的全称是交并比，是目标检测中的一个概念。IoU 计算的是预测的边框和真实的边框之间交集和并集的比值，假设两个边界框的区域为  $A$  和  $B$ ，IoU 计算公式(2-10)：

$$IoU = \frac{A \cap B}{A \cup B} \quad (2-10)$$

FPS 用来衡量模型的检测速度，即每秒内可以处理的图片数量。即 FPS 越大，则模型的检测速度越快。计算量（FLOPs）是用来衡量算法的时间复杂度，这一项参数可以间接的反映模型的检测速度。参数量（Params）是指模型训练中需要训练的参数总数，用来衡量模型的空间复杂度。模型大小则是用来衡量导出模型所占内存的空间大小。通过使用以上这三个指标衡量模型是否达到轻量化标准，满足实时性检测的要求。

## 2.5 数据集介绍

实验中所采用的数据集分为两种：一种是 COCO 2017 数据集，一种是森林山火数据集。首先，使用 COCO 2017 数据集对本文设计的轻量化模型 YOLO-LNet 进行训练，并与当前最先进的轻量级目标检测模型比较；然后通过迁移学习在森林山火数据集上进行训练和验证，以此评估该算法在森林山火数据集上的有效性。COCO 2017 数据集是微软团队提供的一个可以用来进行目标检测的数据集，该数据集包含 80 个类别，共有 163957 张图像，其中 118287 张图像作为训练集，5000 张图像作为验证集，40670 张图像作为测试集。如下图 2-9 所示，展示了部分 COCO 数据集的图像样本。在自建 Fire-Smoke 数据集时，严格遵循了上述准则，采集了 15000 张森林山火样本，随机选择 70%作为训练集，30%作为验证集，以防止类别间的目标数量不平衡问题。如下图 2-10 所示，展示了部分 Fire-Smoke 数据集图像样本。





图 2-9 部分 COCO 数据集图像样本



图 2-10 部分 Fire-Smoke 数据集图像样本

## 2.6 本章小结

本章主要介绍了 YOLO 目标检测算法的基本原理和轻量化技术的相关理论基础。首先，对 YOLO 技术中所涉及到的原理和基本网络结构进行了介绍，并重点介绍了 YOLO 目标检测算法中两个重要的部分：骨干网络和颈部网络；然后，介绍了通道剪枝、特征蒸馏和模型量化等具体的模型压缩方法，并分析了这些方法的原理和关键参数指标。最后，介绍了类平均精度、计算量、参数量、检测速度等性能指标及验证中采用的 COCO 数据集和 Fire-Smoke 数据集。接下来的各章节将紧紧围绕着这些技术和指标展开深入的研究与讨论。

## 第三章 轻量化 YOLO-LNet 模型的设计与验证

### 3.1 引言

无人机具有灵活性强、巡护速度快等优势，在森林山火检测中得到了广泛的关注。无人机山火检测技术将采集到的森林环境图像传输到服务器端，利用部署在服务器端的深度学习算法实现森林山火的检测。然而，基于深度学习的目标检测算法通常计算密集，占用存储空间大，难以在无人机上部署，导致实时性差。为了解决这一问题，研究轻量化 YOLO-LNet 模型，并成功部署在无人机上，是实现森林山火实时检测的关键。

本章将研究轻量化 YOLO-LNet 模型。首先，设计了轻量化 YOLO-LNet 模型，包括轻量化骨干网络的设计、轻量化颈部网络的设计以及轻量化 YOLO-LNet 模型的构建。随后，对轻量化 YOLO-LNet 模型进行了验证，从数据集的预处理、实验环境和超参数的配置、消融实验、模型对比等方面对 YOLO-LNet 展开了验证与测试，以验证 YOLO-LNet 模型的性能。

### 3.2 轻量化 YOLO-LNet 模型的设计

图 3-1 是轻量化模型 YOLO-LNet 的结构示意图，由输入、主干、颈部和输出头组成。为了降低模型的参数量，骨干网络包含一个标准卷积块（Standard Convolutional Block, SCB）和一个轻量级特征提取（Lightweight feature extraction module, LFE）模块，用于对输入图像进行归一化处理并提取特征图。为了降低模型的复杂度，颈部包括上采样路径（up-sampling path, USP）和下采样路径（sub-sampling path, SSP），用于构成多路径聚合特征金字塔结构，以融合不同维度的特征图。设计输出头的目的是获得目标的置信度、类别和位置作为最终输出。




图 3-1 YOLO-LNet 结构示意图

#### 3.2.1 骨干网络的设计

模型的复杂度和内存访问成本决定了模型的检测速度。因此，减少模型参数量和简化模型结构是加快检测速度的最有效途径。这种简化旨在确保算法可以轻



松部署在具有有限内存和低计算能力的嵌入式设备上，并降低功耗。在众多优秀的轻量化模型中，由旷视公司提出的 ShuffleNetv2<sup>[56]</sup>是一个兼具速度和准确性的模型。在该论文中给出了设计轻量化模型的四条准则，并依据这四条准则逐一对 ShuffleNetv1 进行了改进。其中，最具吸引力的是设计了通道重排模块。首先，将输入的通道分成了两部分，一部分向下直接传递，另一部分做向后的卷积运算。然后，在该模块的结尾部分使用通道重排技术，使原始信息和计算后的信息做通道间的交互，实现特征重用的功能。因此，ShuffleNetv2 是一个高效的轻量化模型。为了吸收 ShuffleNetv2 的优秀思想，在本章节 YOLO-LNet 模型的设计中，决定在骨干网络的设计中吸取这种设计思路，实现更加高效的轻量化。

骨干网络包含 SCB 模块和 LFE 结构，用于对输入图像进行归一化处理并提取特征图。SCB 模块作为骨干网络的起始层，主要是对输入图像进行归一化处理，其中包含卷积块 (Conv)、批归一化层 (BatchNorm)、ReLU 激活函数和最大池化层 (MaxPool)，如图 3-2 所示。

LFE 结构由多个组通道重排 (GCS) 模块组成，用于提取特征图，其中每个 GCS 单元由组卷积 (GConv)、通道重排 (CShuf)、深度可分离卷积 (DWSCConv) 和平均池化 (AvePool) 层组成，如图 3-3 所示。GConv 利用卷积对输入图像进行分组，不仅能有效减少计算量，还能获得更多的特征图。CShuf 可以在通道内重组特征图，以获得更多的组内特征。DWSCConv 可以有效减少参数数量，实现轻量化。




图 3-2 SCB 模块示意图




图 3-3 GCS 示意图

图 3-4 显示了深度可分离卷积操作原理，即通过大小为  $M_2 \times 1 \times 3 \times 3$  的输入图像获得大小为  $3 \times 3 \times 3$  的特征图。具体来说，深度卷积  $M_1$  和点卷积  $M_2$  的滤波器数量分别为  $1 \times K \times K$  和  $N \times 1 \times 1$ 。因此，深度可分离卷积  $P_1$  的参数数量可由  $P_1 = M_1 \times 1 \times K \times K + M_2 \times N \times 1 \times 1$ 。




图 3-4 深度可分离卷积操作原理




图 3-5 普通卷积操作原理

图 3-5 显示了普通卷积操作原理，即通过大小为  $M_3 \times 1 \times 3 \times 3$  的输入图像获得大小为  $3 \times 3 \times 3$  的特征图。同样，普通  $M_3$  的滤波器数量为  $N \times K \times K$ 。因此，普通  $P_2$  的参数量可以用  $P_2 = M_3 \times N \times K \times K$ 。

在这两种情况下， $K$  和  $N$  分别代表卷积核的大小和数量。因此，可以用  $P_1$  和  $P_2$  的比值计算得到如公式 (3-1) 的关系：

$$\frac{P_1}{P_2} = \frac{M_1 \times 1 \times K \times K + M_2 \times N \times 1 \times 1}{M_3 \times N \times K \times K} \quad (3-1)$$

由于  $M_1 < M_3$  和  $M_2 = M_3$ ，因此可以计算出如公式 (3-2) 的比例关系：

$$\frac{P_1}{P_2} < \frac{1}{N} + \frac{1}{K^2} \quad (3-2)$$

此外，通常选定  $K > 1$  和  $N > 1$  可以确保公式 (3-3) 的比例关系：

$$\frac{P_1}{P_2} < 1 \tag{3-3}$$

因此，深度可分离卷积可以有效地减少参数量，使骨干网络变得更加轻量化。

YOLO-LNet 的骨干网络采用轻量级组通道重排模块 GCS 构成，为了保证模型检测精度不受损失，通过一定程度的重构网络空间结构，即对模型的层数和结构做了适当调整。该模型使用了 1 层标准卷积层 SCB 和 6 层 GCS，共 7 层作为提取目标特征的骨干网络。对输入的图像进行卷积操作，获取四个不同尺度的特征图，特征图大小分别为 160\*160、80\*80、40\*40 和 20\*20。这样提取到不同尺寸的特征图便具有全局和局部特征，为后续特征融合提供更多信息。输出通道数由最初的 32，增加至 116、232 和 464，通道数的增加意味着能够提取到更加有效的特征。在卷积神经网络中，每个通道都专注不同的特征信息，比如低层次的特征（边缘、细节、纹理等）；高层次的特征（轮廓、形状等）。显然，如此多的特征信息并非三个通道就能够容纳的，通道数越多，所包含的特征信息就越丰富。从而侧面印证了通道数的增加，特征图的尺寸在变小。这也就解释了为什么卷积神经网络能够提取到不同维度的图像特征信息。

表 3-1 描述了 YOLO-LNet 模型骨干网络的结构信息。其中“Layer”表示该层使用的模块名称，“Output size”表示经过该层输出特征图的大小。“Kernel Size”表示卷积核的大小，“Stride”表示卷积核的步长，“Output channels”表示该层的输出通道数。

表 3-1 YOLO-LNet 主干网络配置

| Layer | Output size | Kernel Size | Stride | Output channels |
|-------|-------------|-------------|--------|-----------------|
| Image | 320×320     |             |        |                 |
| SCB   | 160×160     | 3×3         | 2      | 32              |
| GCS1  | 80×80       | 3×3         | 1      | 116             |
| GCS2  | 80×80       | 1×1         | 1      | 116             |
| GCS3  | 40×40       | 3×3         | 1      | 232             |
| GCS4  | 40×40       | 1×1         | 1      | 232             |
| GCS5  | 20×20       | 3×3         | 1      | 464             |
| GCS6  | 20×20       | 1×1         | 1      | 464             |

在 YOLO 系列模型中大量使用标准的 3×3 卷积，而在 YOLO-LNet 模型中 GCS 模块大量使用 3×3 深度可分离卷积，该卷积操作由深度卷积和逐点卷积两个步骤完成。其中，深度卷积使用的是一个 3×3 的卷积核对每个输入通道进行卷积操作，获取中间特征图；然后，进行逐点卷积，使用 1×1 的卷积核将深度卷积的

输出进行线性组合，输出特征图。这种将通道维度和空间维度分离处理的操作，可以在保持相对较低的计算复杂度的同时，提高模型的效率和性能。在 GCS 模块中分别使用了 ReLu 和 SiLu 两种激活函数，SiLu 函数是 Sigmoid 函数的变体，它在取值范围[0,1]内非线性地映射输入，可以增强梯度流动、改善模型的收敛速度和表示能力。ReLu 函数在输入大于 0 时为线性函数，而在输入小于 0 时为 0，用于实现稀疏激活，提供非线性，解决梯度消失，以及加速模型训练的功能。

### 3.2.2 颈部网络的设计

颈部网络具有融合不同维度特征信息的能力，通常是对骨干网络得到的特征图进行放缩，并调整特征图的通道数，以便更好的与输出头配合。在本节颈部网络的设计中，颈部网络包含一个上采样路径和一个下采样路径，以此构成的多路径聚合特征金字塔结构，用于融合骨干网络提取的不同维度特征图。图 3-6 显示了多路径聚合特征金字塔结构示意图。




图 3-6 多路径聚合特征金字塔结构示意图。

具体来说, 上采样路径包含  $n$  个特征图  $D_n$ , 其中  $D_{i+1}$  特征图可以通过连接主干输出  $D'_{i+1}$  的特征图生成, 也可以通过上采样特征图  $D_i$  生成。同样, 子采样路径包含  $n$  个特征图  $F_n$ , 特征图  $F_i$  可以通过连接特征图  $D_i$  和  $F'_i$  获得, 并由下采样特征图生成  $F_{i+1}$ 。同时, 在特征图  $D_n$  和  $F_n$  之间进行映射操作, 以连接上采样路径和下采样路径。

上采样路径由多个分组特征重排(GFS)单元和一个轻量级特征融合(LFF)单元组成, 而下采样路径则包括 GFS 单元和 C3\_LFF 单元。

如图 3-7 所示, 由卷积、深度卷积和通道重排组成的 GFS 单元用于增加特征多样性并丰富通道内的信息, 以获得更高维的特征。




图 3-7 GFS 结构示意图

如图 3-8 所示, 具有残差结构的 LFF 单元利用部分卷积 (PConv) 和普通卷积 Conv 有效地融合空间特征并减少浮点运算 (FLOPs)。如图 3-9 所示, 同样具有残差结构的 C3\_LFF 单元使用了 5 个 LFF 单元, 以方便提取更详细的特征信息, 避免梯度下降。




图 3-8 LFF 结构示意图




图 3-9 C3\_LFF 结构示意图

图 3-10 显示了 PConv 的原理示意图, 该模块只对特征图的部分通道进行卷积处理, 用以减少 FLOPs, 实现模型轻量化。对于高度和宽度分别为  $H$  和  $W$  的输入图像, PConv 的 FLOPs 可以用公式 (3-4) 表示:

$$F_{PConv} = H \times W \times K^2 \times C_p^2 \quad (3-4)$$

其中， $K$  和  $C_p$  分别表示卷积核的大小和滤波器的数量。同样，Conv 的 FLOPs 也可以用公式（3-5）计算：

$$F_{Conv} = H \times W \times K^2 \times C^2 \quad (3-5)$$

其中  $C$  表示滤波器的数量。若选定公式（3-6）的关系：

$$C_p = \frac{C}{4} \quad (3-6)$$

$F_{PConv}$  和  $F_{Conv}$  的比值可由计算公式（3-7）得出：

$$\frac{F_{PConv}}{F_{Conv}} = \frac{1}{16} \quad (3-7)$$

因此，PConv 可以有效地减少 FLOPs，使颈部网络成为一个轻量化的结构。




图 3-10 部分卷积原理图

上采样是特征金字塔中的关键操作，其核心任务是将提取的特征图进行尺寸放大，以获得更高的图像分辨率。常见的上采样方式主要有：最近邻插值、双线性插值、反卷积和动态过滤器等。

最近邻插值或双线性插值上采样方法仅根据像素点的空间位置来确定上采样核，并没有利用到特征图的语义信息，因此可以视为一种“均匀”的上采样方法。此外，这些方法地感知域通常很小（最近邻  $1 \times 1$ ，双线性  $2 \times 2$ ）。相比之下，在反卷积操作中，上采样核不再受限于像素之间的固定距离，而是通过深度学习网络进行自动学习。然而，这种方法也存在局限性，由于它在特征图的每个位置应用相同的上采样核，因此无法很好地捕捉特征图的特征信息。此外，当上采样核的尺寸增大时，模型的参数量和计算复杂度也会相应增加。使用动态过滤器时，模型需要为特征图上的每个像素预测一组不同的上采样核，这样会导致参数量和计算量爆炸，而且使训练这些参数变得更加复杂。

在 YOLO-LNet 的设计中，为了避免最近邻插值上采样方法的局限性，创造性地引入轻量级内容感知特征重组上采样（Content-Aware reassembly of features,

CARAFE) 算子<sup>[57]</sup>。如图 3-11 所示是 CARAFE 算子的两个主要模块：上采样卷积核预测模块和特征重组模块。给定一个大小为  $C \times H \times W$  的特征图  $X$ 。上采样卷积核预测模块采用  $1 \times 1$  卷积层将输入特征通道从  $C$  压缩到  $C_m$ ，减少了输入通道数，使得参数量和计算成本大大降低，从而使 CARAFE 更高效。然后，使用上采样倍率为  $\delta$ ，卷积核大小为  $K \times K$  的内容编码器，得到编码之后大小为  $\delta H \times \delta W \times K^2$  特征图。

由此可知，增加卷积核  $K$  的大小可以扩大编码器的感受野，进而可以利用更大区域内的上下文信息，有利于上采样卷积核的预测。紧接着进行卷积核正则化操作，使用 softmax 函数进行归一化，强制使卷积核值的总和为 1，有利于后续实现特征重组。图中右下部分是特征重组模块，这里以特征图输出的任一特征点  $f_i'$  的目标位置  $l' = (i', j')$  为例进行说明，在输入  $f_i$  处有一个对应的源位置  $l = (i, j)$ ，将输入  $f_i$  以原位置  $l = (i, j)$  为中心，半径为  $K \times K$ ，即  $f_i$  的邻居  $N(f_i, K)$ 。然后将  $f_i$  的邻居  $N(f_i, K)$  区域与上采样卷积核预测模块得到的结果进行重组操作，便可得到卷积核大小为  $\delta W \times \delta H \times C$  的内容感知重组后的特征图  $X'$ 。




图 3-11 内容感知特征重组上采样的原理示意图

### 3.2.3 标签分配策略和损失函数的设计

#### (1) 标签分配策略

在目标检测任务中，标签分配起着至关重要的作用，它决定了模型的学习和收敛。对于基于 Anchor 的目标检测模型，Anchor 与真实框之间的 IoU 是作为判断正负样本的重要依据。

在本研究中，由于无人机拍摄的森林山火画面中包含着大量的小目标（ $32 \times 32$  像素），这些小目标往往只有几个像素大小，所表现出的外观信息极其有限，这就导致识别特征的难度增加，使得小目标的检测非常具有挑战性。通过实验发现，基于 IoU 的方式计算定位框损失，对小目标位置的偏差非常敏感，会严重的降低了检测的性能。

目前，小目标检测的研究方向主要集中在提高特征识别方面。如本章节中设计的多路径特征聚合网络来学习多尺度特征，最终实现尺度不变。事实上，这种方式在一定程度上提高了小目标的检测能力，但这种方式并未从根源上解决问题，是一种治标不治本的方法。

在论文<sup>[58]</sup>中研究表明：IoU 对不同尺度的物体灵敏度差异很大，对于  $6 \times 6$  像素的小物体，微小的位置偏差会导致明显的 IoU 下降（从 0.53 到 0.06），从而导致标签分配不准确。对于  $36 \times 36$  像素的正常物体，IoU 的变化较小（从 0.90 到 0.65），位置偏差相同。这一结果表明 IoU 度量对离散位置偏差的目标尺度是变化的，最终导致标签分配存在以下两个缺陷，其一是由于 IoU 对小目标的敏感性使 Anchor 位置偏差较小，导致正负样本特征相似，网络难以收敛。其次，在小目标数据集中使用 IoU 度量，会使得分配给每个真实框的平均正样本数小于 1，从而导致某些真实框与任何 Anchor 之间的 IoU 低于最小正阈值，从而产生漏检。因此，对于小目标检测算法来说，由于小目标特征信息不足，无法反馈给网络，导致模型只关注中大型目标的特征，而完全忽略掉了对小目标的特征信息的学习。

为了解决使用 IoU 度量所出现的上述问题，提出使用一个 Wasserstein 距离度量边界框相似性来代替标准的 IoU。具体来说，首先将边界框建模为二维高斯分布，然后使用归一化 Wasserstein 距离来度量派生高斯分布的相似性。由公式（3-8）计算真实框和预测框之间的 Wasserstein 距离：

$$W_2^2(N_a, N_b) = \|([cx_a, cy_a, \frac{w_a}{2}, \frac{h_a}{2}]^T, [cx_b, cy_b, \frac{w_b}{2}, \frac{h_b}{2}]^T)\|_2^2 \quad (3-8)$$

其中，真实框和锚框大小分别为  $A=(cx_a, cy_a, w_a/2, h_a/2)$ 、 $B=(cx_b, cy_b, w_b/2, h_b/2)$ 。由于  $W_2^2(N_a, N_b)$  是一个距离度量，不能直接用作相似性度量。因此，使用它的指数归一化形式，得到新的度量，称为 Normalized Wasserstein Distance(NWD)。由和公式（3-9）计算：

$$NWD(N_a, N_b) = \exp(-\frac{\sqrt{W_2^2(N_a, N_b)}}{C}) \quad (3-9)$$

其中 C 是与数据集密切相关的常数。

## （2）损失函数的设计



损失函数由三个部分构成，分别是边界框的回归损失、置信度损失和类别损失。其中，回归损失采用 NWD 度量设计，如公式（3-10）：

$$L_{NWD} = 1 - NWD(N_p, N_g) \quad (3-10)$$

其中， $N_p$  为预测框  $p$  的高斯分布模型， $N_g$  为真实框  $g$  的高斯分布模型。

置信度损失由正样本匹配得到的样本对计算，一是预测框中的目标置信度分数  $p_0$ ，二是预测框和真实框之间的 NWD 值。两者进行二元交叉熵损失（Binary cross-entropy loss, BCE Loss）得到最终的置信度损失，如公式（3-11）：

$$L_{obj}(p_0, p_{NWD}) = BCE_{obj}^{sig}(p_0, p_{NWD}; w_{obj}) \quad (3-11)$$

其中， $BCE_{obj}^{sig}$  表示二元交叉熵损失， $w_{obj}$  表示正样本的权重。

同样，类别损失也采用二元交叉熵损失函数，通过计算预测框的类别分数  $c_p$  和目标框类别的 one-hot 得分  $c_{gt}$  来计算类别损失，如公式（3-12）：

$$L_{cls}(c_p, c_{gt}) = BCE_{cls}^{sig}(c_p, c_{gt}; w_{cls}) \quad (3-12)$$

其中， $BCE_{cls}^{sig}$  表示二元交叉熵损失， $w_{cls}$  表示正样本的权重。

因此，轻量化 YOLO-LNet 模型总的损失函数如公式（3-13）所示：

$$\begin{aligned} L(t_p, t_{gt}) = & \sum_{k=0}^K [\alpha_k^{balance} \alpha_{box} \sum_{i=0}^{S^2} \sum_{j=0}^B \Pi_{kij}^{obj} L_{NWD} \\ & + \alpha_{obj} \sum_{i=0}^{S^2} \sum_{j=0}^B \Pi_{kij}^{obj} L_{obj} + \alpha_{cls} \sum_{i=0}^{S^2} \sum_{j=0}^B \Pi_{kij}^{obj} L_{cls}] \end{aligned} \quad (3-13)$$

其中， $K$ ， $S^2$ ， $B$  分别为输出特征图、cell 和每个 cell 上 anchor 的数量； $\alpha^*$  为对应项的权重，在该模型中分别取值为  $\alpha_{box}=0.05$ ， $\alpha_{cls}=0.36$ ， $\alpha_{obj}=0.64$ ， $\Pi_{kij}^{obj}$  表示第  $i$  个 cell，第  $j$  个锚框，第  $k$  个输出特征图是否为正样本，如果是正样本则为 1，反之为 0； $t_p$  和  $t_{gt}$  分别为预测向量和真实向量； $\alpha_k^{balance}$  用于平衡不同尺度下输出特征图的权重，默认取值为[4.0,1.0,0.4]依次对应三个不同尺度的输出头。

### 3.2.4 YOLO-LNet 模型的构建

在本节中，介绍了一种名为 YOLO-LNet 轻量化森林山火检测模型，其结构框图如图 3-12 所示。图中展示了轻量化 YOLO-LNet 模型的网络结构，其中明确显示了模块的各个层和它们之间的连接方式。




图 3-12 YOLO-LNet 结构框图。

通过对轻量化 YOLO-LNet 模型进行展示，可以清晰地了解轻量化 YOLO-LNet 模型的组成部分和信息流动，从而更好地理解该模型的工作原理和性能特点。

### 3.3 轻量化 YOLO-LNet 模型的验证

#### 3.3.1 数据集的预处理

全球著名人工智能学者吴恩达曾表示：“人工智能=80%数据+20%算法”。可见数据对于深度学习任务结果的影响具有决定性作用，而这主要体现在数据的数量和质量上。

目前，利用互联网爬取的或公开的森林山火数据样本的质量参差不齐，大量数据样本中火灾图像是近距离拍摄的，这部分火灾图像具有发生区域面积大、边界清晰、颜色鲜艳、特征明显的特点；而其中的烟雾图像大多是用流体模型模拟生成的，图像结构单一，形态模糊，不具备真实烟雾飘逸多变的特征。因此，通过互联网搜集的森林山火图片与视频不适用于构建本文的数据集。本文使用无人机视角采集真实场景下的森林山火烟雾图像与部分网络上公开数据集图片，如图 3-13 展示的是无人机采集的山火图像与公开数据集图像对比。




图 3-13 无人机采集的山火图像与公开数据集图像对比：(a)无人机，(b)真实场景下的森林山火图像，(c)公开数据集图片

由于无人机采集的数据多样性十分有限，为了获取更加丰富数据样本，使用了多种数据增广方法。这些方法主要分为两大类：一类是简单数据增广方法，包括平移、翻转、缩放、旋转和添加噪声；另一类是复杂数据增广方法，包括随机擦除、Cutout<sup>[59]</sup>、Cutmix<sup>[60]</sup>、Mixup<sup>[61]</sup>和 Mosaic。通过这些数据增广方法提升算法的准确率，避免模型过拟合，使训练的模型具有更强的泛化能力。同时考虑到后续模型训练、验证和测试的需要，数据集由 Fire-Smoke 单帧数据集和无人机采集的真实山火视频数据组成。

(1) 数据增广

简单数据增广方法是通过对原始训练数据应用一系列变换或处理，仅仅只改变图片的大小、颜色和空间位置的过程。使用简单数据增广方法（平移、翻转、缩放、仿射变换、添加噪声）共得到 1500 张图像样本。如图 3-14 所示，展示了原始图片经过简单数据增广示例。




图 3-14 简单数据增广示例。(a)原图，(b)翻转，(c)亮度，(d)缩放

复杂数据增广方法是通过对一张或多张图像数据进行混叠操作，最终融合成一张图像的过程。使用复杂数据增广（随机擦除、Cutout、Mixup、Cutmix、Mosaic）共得到 4500 张图像样本。以上所使用的五种复杂数据增广方法总结如表 3-2 所示。

表 3-2 五种复杂数据增广方法汇总

| 方法     | 解释                                                       |
|--------|----------------------------------------------------------|
| 随机擦除   | 随机选择图像中的一些区域，然后用随机像素值或某一恒定的数值来覆盖这些区域，模拟图像中部分区域被擦除或遮挡的情况。 |
| Cutout | 随机将图像样本中的部分区域裁剪掉，并填充 0 像素值。                              |
| Mixup  | 随机的将两张样本图像按比例混合。                                         |
| Cutmix | 将一部分区域裁剪掉但不填充 0 像素而是随机填充训练集中的其他数据的区域像素值。                 |
| Mosaic | 随机将几张图片组合成一张图片。                                          |

如图 3-15 所示，展示了原始图片经过复杂数据增广的示例。其中，（a）图展示的是随机擦除方法；（b）图展示的是 Cutout 方法；（c）图展示的是 Mixup 方法；（d）图展示的是 Cutmix 方法。




图 3-15 复杂数据增广示例。(a)随机擦除，(b)Cutout，(c)Mixup，(d)Cutmix

## （2）基于深度学习的暗阴影通道去雾算法设计

通过对自建数据集 Fire-Smoke 整理后发现,在森林中采集的山火图像由于受到林中雾或霾的影响,导致图片细节模糊、对比度低以至于丢失掉目标的重要边缘纹理特征。为了避免这一影响,采用图像去雾算法对数据集中的图像样本进一步处理,提高图像质量。如图 3-16 所示是原始图像样本与暗阴影通道去雾算法处理后的图像样本对比。



图 3-16 原始图像样本与暗阴影通道去雾算法处理后的图像样本对比。(a)原始图像,(b)暗阴影通道去雾处理

目前,图像去雾方法主要包括基于图像增强的去雾算法和基于图像复原的去雾算法。其中,基于图像增强的去雾算法分为直方图均衡化算法、小波变换算法和 Ret-inex 算法,这类方法处理速度快但未考虑图像退化的问题,只是通过提高图像对比度来突出图像的细节特征,并非实际意义上的去雾。基于图像复原的去雾算法分为基于光偏振特性的多幅图像复原、基于先验信息的单幅图像复原和基



于深度学习的去雾方法。这类方法通过利用先验知识，考虑退化本质，但缺点是待估计参数多，而深度学习方法可以很好的解决多参数寻优这一过程。因此，本文采用基于深度学习的暗阴影通道去雾算法来解决数据集中存在的薄雾弥漫的现象。

暗阴影通道去雾算法中的“暗通道”是一个基本假设，该假设认为在绝大多数非天空的局部区域中，存在一些像素点（暗像素）在至少一个颜色通道中具有非常低的值，趋近于 0。暗通道实际上是在 RGB 三个通道中取最小值组成灰度图，然后再通过一个最小值滤波得到的。《Single Image Haze Removal Using Dark Channel Prior》<sup>[62]</sup>通过在 5000 张图片上统计图像的特征发现，有雾的时候会呈现一定的灰色，而无雾的时候会呈现大量的黑色（像素值接近 0）。在计算机视觉中，该论文将有雾图像的模型描述为公式(3-14)：

$$I(x) = J(x)t(x) + A(1-t(x)) \quad (3-14)$$

其中  $I(x)$  为观察到的有雾图像， $J(x)$  为无雾图像， $A$  是大气光值， $t(x)$  为透射率，表示能够到达计算机系统的没有被散射掉的一部分光。

本论文设计了基于深度学习的暗阴影通道去雾模块，其核心思想是利用卷积神经网络对大气退化模型中的透射率  $t(x)$  进行估计。其输入是烟雾图像，输出是经透射率  $t(x)$  的映射图，然后通过大气退化模型来恢复无烟雾弥漫的图像。主要包含四个组成部分：特征提取、多尺度映射、局部极值和非线性回归。为了清晰的了解以上四个部分，下面将分别对这四个组成部分进行详细地阐述。基于深度学习的暗阴影通道去雾模块的结构框图如图 3-17 所示。




图 3-17 基于深度学习的暗阴影通道去雾模块结构框图

### 1) 特征提取

特征提取并不是采用传统的卷积神经网络，而是采用“卷积+Maxout”的结构作为网络的第一层。其数学原理如公式（3-15）和公式（3-16）所示：

$$F_1^i(x) = \max_{j \in [1, k]} f_1^{i,j}(x) \quad (3-15)$$

$$f_1^{i,j} = W_1^{i,j} * I + B_1^{i,j} \quad (3-16)$$

其中， $F$  代表输出的特征， $i$  表示第  $i$  个特征，1 是指第一层， $k$  表示  $k$  个层的 maxout 操作。 $W$  和  $B$  分别表示权重和偏置。

之所以选择“卷积+Maxout”作为特征提取的第一层，是因为这步操作等价于手工提取烟雾特征。当 $W$ 是反向滤波器，通道的最大值经过反向滤波器后等价于通道的最小值，相当于暗通道先验值；当 $W$ 是环形滤波器，相当于最大对比度；当 $W$ 同时包含反向和全通滤波器，等价于特征图从RGB转换到HSV颜色空间，相当于颜色衰减先验。

2) 多尺度映射

使用多尺度并行卷积操作，即同一张图使用不同的卷积核进行卷积。如图 3-18 所示是多尺度特征映射的原理图。分别使用 16 个 $3\times3$ 、16 个 $5\times5$ 和 16 个 $7\times7$ 的卷积进行卷积操作，每一种尺度便可产生 16 个特征图，并通过 padding 操作将其填充为尺度大小一样的。




图 3-18 多尺度特征映射的原理图

3) 局部极值

根据假设透射率具有局部不变性，因此使用一个  $7\times7$  的局部最大值滤波器代替最大池化。

4) 非线性回归

大气透射率是一个概率（0 到 1），不可能无穷大，也不可能无穷小。因此受 Sigmoid 和 ReLU 函数的启发，设计了双边纠正线性单元（BReLU），在双边约束下，保证局部是线性的。如图 3-19 是单边纠正线性单元（ReLU）和双边纠正线性单元的函数图像。




图 3-19 (a) ReLU 函数图像; (b) BReLU 函数图像

### (3) 数据集结构与划分

数据集主要分为训练集、验证集和测试集三个部分。训练集用于训练模型拟合数据样本；验证集用于评估训练过程中的模型性能，帮助调整模型的权重，并计算准确率、召回率等评价指标用于验证当前模型的泛化能力；测试集是用于客观评估模型的性能，但无法改变模型。

数据的来源主要是两个部分，一部分是用无人机搭载的高清摄像头实地捕捉的真实森林山火样本，另一部分是通过数据增广的方法得到的。其中真实采集的样本为 9000 张，数据增广方法得到 6000 张，共计 15000 张。训练集和验证集划分如表 3-3 所示。

表 3-3 训练集和验证集的划分

| 类别  | 真实采集 | 数据增广 | 合计    |
|-----|------|------|-------|
| 训练集 | 6000 | 4500 | 10500 |
| 验证集 | 3000 | 1500 | 4500  |
| 合计  | 9000 | 6000 | 15000 |

尽管本文构建了完备的训练集和验证集，但是为了客观的评价模型的性能，最终选择通过真实森林山火视频进行测试。该测试集是从 10 段不等长的真实森林山火视频中截取的，总帧数为 20000。其中，有火的帧数为 791，无火的帧数为 709，有烟雾的帧数为 890，无烟雾的帧数为 610，总共选取帧数为 3000。其详细情况如表 3-4 所示：

表 3-4 测试集的详细信息。

| 视频数目 | 总帧数   | 选取有火<br>帧数 | 选取无火<br>帧数 | 选取有烟<br>帧数 | 选取无烟<br>帧数 | 总选取帧<br>数 |
|------|-------|------------|------------|------------|------------|-----------|
| 10   | 20000 | 791        | 709        | 890        | 610        | 3000      |



(4) 半自动数据标注工具开发

数据标注是目标检测任务中非常重要的环节。简单来说，数据标注就是对采集到的图像样本或视频数据进行加工处理，从而转变成算法可以识别的过程。图像标注的一个难点就是数据量多，标注工作量大，难以在短时间内完成。为了克服这一难点，在研究过程中所有数据标注任务，都采用本文开发的半自动数据标注图形化软件——Auto LabelImg。由于标注的标签格式是 YOLO 形式的，因此，这个图形化软件采用基于 YOLOv5 检测模型并结合 PYQT 开发的，可实现半自动标注。虽然还不能实现完全自动标注，但已经可以大大减少工作量，只需手动微调便可实现精准标注。如图 3-20 所示，是半自动图形化软件——Auto LabelImg 的设计流程图。




图 3-20 Auto LabelImg 的设计流程图

(5) 锚框(Anchor)聚类

Anchor 是目标检测任务中的一种先验框，可以用聚类等无监督的方法获取。YOLO 系列目标检测算法中的 Anchor 是由宽（W）和高（H）组成，用的是原像素中的尺寸，表示图像样本中目标的形状位置，通过三种长宽比不同的 Anchor，分别对应大、中、小三种不同尺寸的目标。将特征图分为 3 个不同尺寸的通道，每个通道对应生成 3 个 Anchor，总共有 9 个比例大小不一的 Anchor。使用 Anchor 的好处相当于是给模型添加了先验知识，使模型一开始就记住了数据样本的形状，这样就加快了正负样本的学习。

在 YOLO 系列中最新的模型采用的是 K-Means 算法对 COCO 数据集生成锚框, 并采用遗传算法在训练过程中调整锚框。由 K-Means 算法的原理可知, 在使用 K-Means 聚类的过程中, 该算法会在正式聚类之前首先初始化 K 个簇中心。正是由于这一过程, 使得 K-Means 聚类算法存在着一个巨大的缺陷——收敛情况严重依赖于簇中心的初始化状态。为了克服这一问题, 针对于自建森林山火数据集采用 K-Means++算法可以有效解决这一问题, 从而在一定程度上提高模型的检测精度。

K-Means++算法实际上是修改了 K-Means 算法的第一步操作, 不再让随机选取的中心点只趋于局部最优解, 而是让其尽可能的趋于全局最优解。只有尽可能地保证各个簇中心的距离尽可能的远, 才能够保证中心点之间不会在同一个簇内, 这样就会在迭代过程中不断调整簇的形状, 使算法收敛到正确的形状。如表 3-5 是使用 K-Means++聚类 Fire-Smoke 数据集生成的 Anchor。

表 3-5 K-Means++算法聚类生成 Anchor 大小

| 类别 | Anchors        |               |                 |
|----|----------------|---------------|-----------------|
| 大  | [87.62,163.81] | [136.0,112.0] | [147.94,216.89] |
| 中  | [54.4,121.6]   | [59.73,49.92] | [82.13,81.78]   |
| 小  | [12.8,21.33]   | [25.6,37.93]  | [35.2,75.73]    |

### 3.3.2 实验环境和超参数配置

实验环境是由 PC 主机, 主要用于训练和验证轻量化模型 YOLO-LNet。PC 主机的配置是基于 Ubuntu16.04 的 Linux 操作系统, CPU 的型号是 Intel(R) Xeon(R) CPU E5-2678 v3 @ 2.50GHz, GPU 是由 4 块 NVIDIA GeForce RTX 2080 Ti 组成, 每块 GPU 的显存大小为 11G, CUDA 版本为 10.2。实验中使用的深度学习框架为 Pytorch1.8。

超参数是一组在开始学习之前就设置好的参数。通常情况下, 需要对超参数进行优化, 以提高学习的性能和效果。表 3-6 给出了 YOLO-LNet 模型训练过程中的超参数。

表 3-6 模型训练超参数设置

| 类型             | 超参数    | 说明        |
|----------------|--------|-----------|
| Epoch          | 300    | 迭代次数      |
| Batch size     | 64     | 每次迭代送入图片数 |
| Learning rate1 | 0.01   | 初始学习率     |
| Learning rate2 | 0.0001 | 最小学习率     |
| Momentum       | 0.937  | 动量优化器     |
| Weight decay   | 0.0005 | 权重衰减      |

3.3.3 消融实验

为了直观对比 YOLO-LNet 的改进效果，本节对设计的 YOLO-LNet 模型各部分进行了消融实验，并在 Fire-Smoke 数据集上进行了训练和验证，并记录了 mAP@0.5、FLOPs、Params、FPS 和模型大小各项指标，以确定改进的效果。表 3-7 展示了基于 YOLOv5s 框架设计的 YOLO-LNet 模型各部分性能指标。

表 3-7 YOLOv5s 和 YOLO-LNet 的性能比较

| 模型        | mAP@0.5(%) | 计算量<br>(GFLOPs) | 参数量<br>(M) | 速度 (FPS) | 模型大小<br>(MB) |
|-----------|------------|-----------------|------------|----------|--------------|
| YOLOv5s   | 70.6       | 15.8            | 7015519    | 63       | 14.4         |
| YOLO-G    | 69.0       | 0.8             | 332324     | 111      | 1.0          |
| YOLO-GG   | 70.8       | 0.8             | 273899     | 107      | 0.91         |
| YOLO-GGL  | 70.7       | 0.7             | 261595     | 110      | 0.88         |
| YOLO-LNet | 71.2       | 0.7             | 261489     | 110      | 0.87         |

其中，YOLOv5s 作为基准模型，以下各部分的设计均是在该模型的基础上构建的，YOLO-G 表示的是骨干网络选用轻量化特征提取结构 LFE；YOLO-GG 表示在上一步的基础上，再将多尺度特征融合网络中的普通卷积算子改为分组特征重排(GFS)单元；YOLO-GGL 表示在上一步的基础上，将颈部网络中用于特征融合模块改为轻量级特征融合(C3\_LFF)单元构成的残差结构，用于整合不同尺度的特征；同样的，YOLO-LNet 表示在上一步的基础上，将颈部网络中最近邻上采样算子改为轻量级通用上采样算子 CARAFE。

从表 3-7 的结果可以得出，YOLO-LNet 的每一步重构，模型的性能都有一定程度的提升。在上述改进过程中，基于轻量化特征提取结构 LFE 设计得骨干网络性能提升最为明显，与 YOLOv5s 模型相比，YOLO-G 模型的 FLOPs 下降了 94.94%，参数量减少了 95.26%，检测速度 FPS 提高了 76.19%，模型大小仅为

1.0MB, 但  $mAP@0.5$  仅下降了 1.6%。YOLO-GG 模型的  $mAP@0.5$  相比于 YOLO-G 提高了 1.8%, 参数量减少了 17.58%。而 YOLO-GGL 的计算量仅为 0.7GFLOPs, 检测速度达到 110FPS, 模型大小为 0.88MB。最终, YOLO-LNet 模型得结果表明, 模型的 FLOPs 与源模型 YOLOv5s 相比下降了 95.57%, 参数量下降了 96.10%, 检测速度 FPS 提高了 2.14 倍, 模型大小仅为 0.87MB,  $mAP@0.5$  提升了 0.6%。

综上所述, 轻量化骨干网络得的设计可以大幅降低模型的复杂度, 减少模型的参数; 颈部网络中采用多尺度特征融合网络和轻量化上采样算子 CARAFE 可以在不增加模型参数量的情况下, 提高模型的检测精度。以上这些都反映了本文设计的模型不仅足够的轻量化, 而且检测速度也是非常的快。




图 3-21 YOLOv5s 模型与 YOLO-LNet 消融模型的 epoch-loss 曲线

图 3-21 展示了 YOLO5s 模型与 YOLO-LNet 消融模型的 epoch-loss 曲线。通过该曲线可以发现, YOLOv5s 模型在迭代次数为 204 次时, 模型收敛停止训练, loss 值为 0.063286; YOLO-LNet 模型在经过各个模块的消融实验后, 最终模型在学习了 184 次就达到收敛了, loss 值为 0.053951; 经过改进的模型 YOLO-LNet 无论是在迭代次数上, 还是在最终的 loss 值上都达到比较好的效果。从模型训练的角度来说, 本文所设计的模型具有较为快速的学习能力, 能够满足森林山火复杂场景下快速训练部署的需求。

### 3.3.4 对比实验

#### (1) 轻量级 SOTA 模型对比

为了研究 YOLO-LNet 算法的优异性能, 本节使用 COCO 2017 数据集进行验证。该数据集包含了 80 个不同类别的大、中、小目标, 能够全面的反映算法的检测性能。在对比实验中, 选择目前先进的轻量化目标检测网络 YOLO-fastest、YOLOv5-Lite、NanoDet-m。所有算法都在同一设备和相同的超参数设置下进行训练、验证以及测试。本实验中, 选用  $mAP@0.5$ 、 $mAP@.5:0.9$ 、计算量 (FLOPs)、参数量 (Params) 和模型大小等指标评估上述算法的性能。表 3-8 显示了每种算法在 COCO 数据集上的检测结果。

表 3-8 轻量级 SOTA 算法在 COCO 数据集上的性能

| 模型           | $mAP@0.5(\%)$ | $mAP@.5:0.9(\%)$ | 计算量<br>(GFLOPs) | 参数量<br>(M) | 模型大小<br>(MB) |
|--------------|---------------|------------------|-----------------|------------|--------------|
| YOLO-fastest | 24.4          |                  | 0.25            | 0.35       | 1.4          |
| YOLOv5-Lite  | 35.1          |                  | 0.73            | 0.78       | 1.7          |
| NanoDet-m    |               | 20.6             | 0.72            | 0.95       | 1.8          |
| YOLO-LNet    | 37.2          | 21.3             | 0.70            | 0.26       | 0.84         |

从表 3-8 的结果可知, 本文设计的轻量化模型 YOLO-LNet 在 COCO 数据集上相比于其它先进的模型都表现出色。在检测精度方面, YOLO-LNet 模型的  $mAP@0.5$  达到了 37%, 比第二名的 YOLO-Lite 模型高出 2.1%。与 YOLO-fastest 和 NannoDet-m 模型相比, YOLO-LNet 的  $mAP@0.5$  和  $mAP@.5:0.95$  分别提高了 12.8%和 0.7%。在模型复杂度上, YOLO-LNet 模型的 FLOPs 略低于 YOLOv5-Lite 和 NanoDet-m, 但高于 YOLO-fastest; 在参数量和模型大小方面, 均优于其它模型, 参数量和模型大小仅为 0.26M 和 0.84MB。因此, 与先进的轻量化目标检测算法相比, YOLO-LNet 具有更高的检测精度和更少的参数量。

## (2) 与 YOLO 系列模型对比

为了证明 YOLO-LNet 在森林山火目标检测中的有效性, 选用 YOLO 系列中性能表现良好的模型, 如 YOLOv5-Lite、YOLOv5s、YOLOv7-Tiny、YOLOv8s 在 Fire-Smoke 数据集进行了验证。所有算法均使用同一设备和相同的超参数进行训练、验证和测试。本实验中, 选用  $mAP@0.5$ 、计算量、参数量和模型大小, 这四项指标评估上述算法的性能。表 3-9 展示了 YOLO 系列算法在 Fire-Smoke 数据集上的检测结果。

表 3-9 YOLO 系列算法与轻量化模型 YOLO-LNet 的性能对比

| 模型          | mAP@0.5(%) | 计算量<br>(GFLOPs) | 参数量 (M) | 模型大小<br>(MB) |
|-------------|------------|-----------------|---------|--------------|
| YOLOv5s     | 70.6       | 15.8            | 7.02    | 14.4         |
| YOLOv7-Tiny | 72.0       | 3.4             | 1.51    | 3.3          |
| YOLOv8s     | 72.5       | 38.4            | 11.12   | 22.5         |
| YOLO-LNet   | 71.2       | 0.7             | 0.26    | 0.9          |

表 3-9 的实验结果表明,本章设计的 YOLO-LNet 模型相比于 YOLO 系列先进的模型在森林山火检测方面都表现卓越。与检测准确性最好的 YOLOv8 模型相比, YOLO-LNet 模型的参数量只有其 2.3%, 计算量减少了 97.5%, 模型大小减少到 0.87MB, 但代价是 mAP@0.5 减少了 1.3%。与轻量级 YOLOv5-Lite 模型相比, 参数量减少了 0.07M, 计算量减少了 12.5%, 模型大小减少了 0.13MB, 但 mAP@0.5 提高了 2.2%。由此, 通过采用轻量化骨干网络, 改进的多尺度特征融合的颈部网络以及采用轻量级的通用上采样算子等方法, 得到了一个足够轻量化且检测精度较好的森林火灾检测模型。以上结果无不表明, 本章设计的轻量化模型 YOLO-LNet 具有优越的性能。

### (3) 与其他系列森林山火模型对比

为了进一步分析轻量化 YOLO-LNet 模型的检测性能, 在 Fire-Smoke 数据集上进行了测试。分别与 RetrianNet、EfficientDet、mobileViT 和 YOLOX 模型进行了比较, 每个模型 mAP@.5、检测速度、计算量、参数量和模型大小如表 3-10 和图 22 所示。

表 3-10 与其他系列森林山火模型比较

| 模型           | mAP@0.5(%) | 检测速度<br>(FPS) | 计算量<br>(GFLOPs) | 参数量(M) |
|--------------|------------|---------------|-----------------|--------|
| RetrianNet   | 68.7       | 47.3          | 145.3           | 36.3   |
| EfficientDet | 69.7       | 63.7          | 104.9           | 20.5   |
| YOLOX        | 70.2       | 87.2          | 26.8            | 9      |
| mobileViT    | 70.4       | 92.1          | 0.7             | 1.2    |
| YOLO-LNet    | 71.2       | 110.3         | 0.7             | 0.26   |

从表 3-10 中可以看出, 轻量化 YOLO-LNet 模型在 mAP@.5、检测速度、计算量、参数量和模型大小等性能方面全面领先 RetrianNet、EfficientDet、mobileViT 和 YOLOX 模型。相比于表现最好的 mobileViT 模型, mAP@0.5 提高了 0.8%, 检测速度提升了 16.5%, 参数量下降了 78.3%。




图 3-22 与其他系列森林山火模型比较

(4) 模型可视化分析

模型通道间特征图可视化能够反映模型各通道之间提取特征的能力。这些特征包含了图像的低层特征（边缘、颜色和纹理等）和高层特征（语义信息等），通过对不同通道特征信息的获取，可以有效地调整模型的特征提取能力，使模型对目标的检测准确性更高。以图 3-20 为例，展示了本文所设计的轻量化森林山火检测模型 C3\_LEF 层输出的特征图（第 21 层的输出）。




图 3-23 C3\_LEF 层通道内提取到的特征图。(a)原始图片，(b)C3\_LEF 层的输出特征图

为了更加直观的看到模型输出层对不同目标的关注程度，使用可视化方法 Grad-CAM++ 算法<sup>[63]</sup>得到输出层的热力图，用于显示图像中不同区域的热度或重要程度。在该方法中，热力图被用来表示物体在图像中的位置和置信度。通过将热力图叠加到原始图像上，可以直观地显示出检测结果，帮助我们更好地理解模型的性能和行为。

Grad-CAM++ 算法是一种基于梯度定位的模型可解释性分析方法。该算法是 Grad-CAM 算法的升级版，主要是为了克服 Grad-CAM 算法中利用目标特征图的梯度求平均获取特征图权重，即梯度特征图上每一个元素的贡献是一样的。而在 Grad-CAM++ 算法中梯度特征图上的每一个元素的贡献都不同，额外增加了一个权重对梯度特征图的元素进行加权，见公式(3-15)：

$$W_k^c = \sum_i \sum_j \alpha_{ij}^{kc} \cdot \text{relu}\left(\frac{\partial Y^c}{\partial A_{ij}^k}\right) \quad (3-17)$$

其中该权重  $\alpha_{ij}^{kc}$  如公式(3-16)：

$$\alpha_{ij}^{kc} = \frac{\frac{\partial^2 Y^c}{(\partial A_{ij}^k)^2}}{2 \frac{\partial^2 Y^c}{(\partial A_{ij}^k)^2} + \sum_a \sum_b A_{ab}^k \left\{ \frac{\partial^3 Y^c}{(\partial A_{ij}^k)^3} \right\}} \quad (3-18)$$

其中  $c$  为目标类别， $k$  表示特征图的第  $k$  层（第  $k$  个通道）， $i, j$  为该层特征图上的元素位置， $A^k$  是特定激活图， $Y^c$  是任意预测得分，要求此项必须是可导函数。如图 3-24 所示，展示的是使用 Grad-CAM++ 算法可视化效果图。






图 3-24 Grad-CAM++算法可视化效果图。(a) 真实森林山火图像, (b) Grad-CAM++热力图

通过 Grad-CAM++算法可视化结果可知,轻量化 YOLO-LNet 模型对火焰和烟雾的定位准确性方面表现良好。通过对模型所关注目标特征的可视化,更加直观的说明了模型对火焰和烟雾目标具有一定程度的理解能力,有利于对模型精度做进一步提升。

在使用 Grad-CAM++ 算法对目标热力图进行可视化的过程中，可以得到 CAM 类激活图算法成功使用的两个关键条件：①输入图像经过卷积神经网络处理后，其最后一层为卷积层的输出特征图；②权重类别应与输入图像类别相关、类别数量和特征图通道数一致。在满足这两个条件的前提下，只需要将二者对应相乘相加即可得到类别显著图。但是这两个要素在神经网络中不具有普遍适用性，比如对于 VGG、DenseNet 等这一类模型来说，不满足上述第二个条件。因此，Grad-CAM++ 算法为了解决这一问题，采用特征图的梯度信息生成相应的权重。但需要注意的是，这里的梯度不是模型训练时由损失反向传播计算得到的梯度，而是模型输出的类别置信分数反向传播计算得到的梯度。因为这里的权重只有包含类别信息才有意义，比如对于一幅图片中包含两个类别（猫和狗）的目标，使用 CAM 算法进行定位猫还是狗的情况时，如果使用与输出类别中的猫相关的信息获得的权重筛选出来的特征图点亮了猫所在的区域，而用输出类别中编码狗的分类分数信息获得的权重筛选出来的特征图点亮了狗所在的区域，那么就可以很好的解释了神经网络是如何判别猫还是狗的。因此，CAM 算法中的权重其实具有通过类别信息来筛选相应的特征图的功能。

#### （5）检测结果分析

通过对测试集中包含的近景、远景、单一以及复杂多目标等不同情况的样本进行测试。如图 3-25 是测试集中的远景目标和近景目标的测试效果图。




图 3-25 是测试集中的远景目标和近景目标的测试效果图。(a)远景目标，(b)近景目标

图 3-26 展示了单一目标和复杂多目标场景下轻量化 YOLO-LNet 的检测结果图。



图 3-26 单一目标和复杂多目标场景下检测结果图。(a)单一目标，(b)复杂多目标

通过观察上面的检测效果图，可以发现：简单目标与远景小目标的检测的效果都比较不错，这主要的得益于简单目标形态比较清晰，相对容易检测。此时正值火灾或烟雾发生的中间阶段，此时火焰或烟雾比较清晰。此时如果天气晴朗，能见度较高，对于火焰和烟雾的检测来说也相对容易。

另一方面，对于复杂目标和近景大目标的误检及定位准确性会出现不同程度的下降，如图 3-27 所示。这主要是由于复杂目标形态不清晰，火焰和烟雾同时出现在同一检测画面中，对于二者的检测来说，目标多且复杂，不易准确检测出来。其次是烟雾的检测会出现很多误检情况，造成虚假信息的误报，影响实际的检测效果。而对于近景大目标来说，虽然局部特征信息比较明显，但对于全局信息来说丢失了很多高维语义信息，检测时只能检测出部分区域，而无法做到全局检测。






图 3-27 漏检和误检情况展示。(a)漏检情况，(b)误检情况

### 3.4 本章小结

本章对轻量化 YOLO-LNet 模型的设计与验证展开了研究。对于轻量化骨干网络的研究，设计了由组通道重排单元组成的轻量级特征提取模块；对于轻量颈部网络的研究，设计了由轻量级特征融合（LEF）单元和改进的 C3\_LEF 单元组成的多路径聚合的特征金字塔结构。最后，从类平均精度  $mAP@0.5$ 、检测速度 FPS、计算量（FLOPs）、模型参数量（Params）和模型大小等方面对骨干网络和颈部网络进行了测试，验证了轻量化骨干网络、轻量化颈部网络以及轻量化 YOLO-LNet 模型的性能。

在消融实验中，轻量化骨干网络 YOLO-G 的实验结果表明，该模型的  $mAP@0.5$ 、速度、计算量和参数量分别为 69.0%、111FPS、0.8GFLOPs 和 0.33M，优于基准模型 YOLOv5s 的  $mAP@0.5$ （70.6%）、速度（63FPS）、计算量（15.8GFLOPs）和参数量（7.02M）。结果表明，YOLO-G 具有良好的性能。

在消融实验中，轻量化颈部网络 YOLO-GGL 的实验结果表明，该模型的  $mAP@0.5$ 、速度、计算量和参数量分别为 70.7%、110FPS、0.7GFLOPs 和 0.26M，

优于基准模型 YOLOv5s 的  $mAP@0.5$  (70.6%)、速度 (63FPS)、计算量 (15.8GFLOPs) 和参数量 (7.02M)。结果表明, YOLO-GGL 具有良好的性能。

与 YOLO 系列模型进行对比实验, 轻量化 YOLO-LNet 模型在 Fire-Smoke 数据集上的实验结果表明, 该模型的  $mAP@0.5$ 、计算量、参数量和模型大小分别为 71.2%、0.7GFLOPs、0.26M 和 0.9MB, 优于 SOTA 模型 YOLOv8s 的计算量 (38.4GFLOPs)、参数量 (11.12M) 和模型大小 (22.5MB)。结果表明, YOLO-LNet 具有更低的计算复杂度、更少的参数量以及更小的存储需求。

与轻量级检测模型进行对比实验, 轻量化 YOLO-LNet 模型在 COCO 数据集上的实验结果表明, 该模型的  $mAP@0.5$ 、 $mAP@.5:0.9$ 、计算量、参数量和模型大小分别为 37.2%、21.3%、0.70GFLOPs、0.26M 和 0.87MB, 优于 SOTA 模型 YOLO-fastest 的  $mAP@0.5$  (24.4%)、参数量 (0.35M) 和模型大小 (1.40MB)。结果表明, YOLO-LNet 具有更高的检测精度、更少的参数量以及更小的存储需求。

与其它森林山火检测算法相比, 轻量化 YOLO-LNet 模型在  $mAP@.5$ 、检测速度、计算量、参数量和模型大小等性能方面全面领先 RetrianNet、EfficientDet、mobileViT 和 YOLOX 模型。相比于表现最好的 mobileViT 模型,  $mAP@0.5$  提高了 0.8%, 检测速度提升了 16.5%, 参数量下降了 78.3%。

综上, 轻量化 YOLO-LNet 模型具有优异的性能。

## 第四章 超轻量化 YOLO-ULNet 模型的设计与验证

### 4.1 引言

深度学习模型压缩技术是利用神经网络参数和结构的冗余性精简模型，在不影响精度的情况下，使得模型的参数量更少、结构更精简。最终被压缩后的模型对计算资源和内存的需求更小，相比原始模型更能满足低算力嵌入式设备的需求，有利于推理速度的提升。

本章对超轻量化 YOLO-ULNet 模型的设计展开了研究，并进行实验验证。首先，对于超轻量化 YOLO-ULNet 模型的设计，采用了改进的通道剪枝技术，获得了精简的模型；采用了改进的特征蒸馏技术，获得了超轻量化 YOLO-ULNet 模型。然后，从 mAP@0.5、速度、计算量和参数量对超轻量化 YOLO-ULNet 模型进行了验证。最后，对超轻量化 YOLO-ULNet 模型进行部署，并对其进行了 int8 量化。从检测精度和检测速度两个方面对超轻量化 YOLO-ULNet 模型在无人机上进行测试，以验证超轻量化 YOLO-ULNet 模型的性能。

### 4.2 超轻量化 YOLO-ULNet 模型的设计

#### 4.2.1 改进的通道剪枝技术

通道剪枝是一种用于减少神经网络中参数数量和计算复杂度的技术。其核心原理是利用 BN 层中的稀疏化比例因子  $\gamma$  将卷积层中的每个通道关联起来，在训练过程中对这些缩放因子进行稀疏正则化，以自动识别不重要的通道。

尽管 YOLO-LNet 模型采用了全新的轻量化网络设计方法，但通过稀疏化训练可以发现，其中的权重、通道和网络层数仍存在着一定程度的冗余。因此，有必要考虑应用通道剪枝技术，以确保在模型检测精度不出现大幅下降的前提下，剔除掉其中的冗余参数和不重要的通道。

为了不改变现有模型结构，本文提出的方法主要是利用通道稀疏性来压缩模型结构。与权重剪枝、滤波器剪枝和神经元剪枝等方法相比，该方法可以更高效减少模型的体积，显著减少模型的参数量和计算量，从而减少模型需要的存储空间和推理时间。因此，本文所用的方法主要是对模型通道进行裁剪。首先，将稀疏化比例因子  $\gamma$  插入到模型各个通道的 BN 层中；然后，通过  $L_1$  正则化方法进行稀疏化并与权重一起训练来进行调整；最后，将卷积核权重之和较小的通道视为冗余通道并作删除处理。BN 层执行的操作如公式（4-1）所示：

$$y = \gamma \frac{x - \mu_b}{\sqrt{\sigma_b^2 + \xi}} + \beta \quad (4-1)$$

其中,  $\mu_b$  和  $\sigma_b^2$  分别为输入特征图  $x$  的均值和方差,  $\xi$  为修正系数,  $\beta$  为偏置,  $y$  为输出特征图。

使用  $L_1$  正则化方法对通道进行稀疏化处理, 可以得到许多权重接近于 0 的通道, 这就意味着相应通道被“阻断”了, 进而实现了通道剪枝。因此, 可以通过检测其所有中间层的输入和输出连接以及相应的通道缩放因子来修剪通道, 达到通道剪枝的目的。如图 4-1 所示, 剪枝后的模型与原模型相比, 能够得到更加紧凑的模型结构。当稀疏化比例因子  $\gamma$  值低于某个阈值  $\delta$  时, 关闭该通道; 反之, 则保留该通道。




图 4-1 示意图(a)通道修剪前; (b)通道修剪后。

本文借鉴了 2017 年 Liu 等人提出的“网络瘦身”算法, 该算法采用典型的“三步”训练策略对模型进行精简。首先, 模型经过稀疏化训练, 然后进行剪枝操作, 最后进行微调, 以生成一个相对精简的模型, 同时并保持了相对较高的准确度。这种方法可以保证在不牺牲太多性能的情况下减少模型的尺寸。其中, 稀疏化比例因子  $\gamma$  和剪枝率  $\lambda$  是两个超参数, 在手动设置时需要进行平衡, 以确保模型在减少参数数量的同时, 精度不会下降太多。如图 4-2 所示是稀疏化比例因子  $\gamma$  设置为 0.005 时, 得到的 BN 层权重值与通道个数的关系。




图 4-2 不同 BN 层权重值与通道个数关系图

通过设置不同大小的稀疏化比例因子  $\gamma$ ，观察权重靠近 0 的通道个数，进而能够得到不同稀疏化比例因子下冗余通道数量对准确度  $mAP@0.5$  的影响，如图 4-3 所示。




图 4-3 稀疏化比例因子和冗余通道数量对准确度  $mAP@0.5$  的影响



稀疏化的目的是为了得到更多权重为 0 的通道。图中横轴代表不同的稀疏化比例因子  $\gamma$ ，纵轴代表权重接近于 0 的通道个数，即冗余通道的数量。从图 4-3 中可以得出，随着稀疏化比例因子  $\gamma$  逐渐增大，靠近 0 的通道数越多，即稀疏化的效果就越好。但为了平衡精度，也并非稀疏化比例因子  $\gamma$  越大越好，可以看到模型精度会随着稀疏化比例因子  $\gamma$  的增大而减小。因此，应选择一个合适的  $\gamma$  值来兼顾精度和通道数量，本文选择的  $\gamma = 0.008$ 。

通过观察图 4-4 可知，当稀疏化比例因子  $\gamma = 0.008$  时，随着剪枝率从 0% 一直增加到 85%，模型的参数量迅速下降，而  $mAP@0.5$  基本保持平稳下降，但当剪枝率从 85% 增加到 90% 时，模型精度开始出现较大幅度的下降，值得注意的是，当剪枝率达到 86% 时， $mAP@0.5$  出现显著下降；因此，为了在通道剪枝中取得最佳性能，本文将剪枝率设置为 85%。最后，对剪枝后的模型进行微调以进一步提高性能。




图 4-4 剪枝率对  $mAP@0.5$  的影响

### 4.2.2 改进的特征蒸馏技术

特征蒸馏是一种更加精细的知识蒸馏方法，它不仅能将模型的输出知识传递给蒸馏模型，还能将中间层的特征知识进行传递，从而进一步提高模型的性能。此外，特征蒸馏可以在训练过程中自适应地调整目标模型的特征表示能力，以适应不同的任务需求。

在上一节使用通道剪枝对设计的轻量化模型 YOLO-LNet 进行模型压缩的过程中，虽然通道剪枝可以剔除大量“不重要”通道，使得模型的参数量和计算量大幅降低；但不可避免地会在一定程度上降低对火焰和烟雾的检测精度。因此，

为了有效地解决通道剪枝过程中引发的检测精度下降的问题，本文采用特征蒸馏技术作为对通道剪枝的补充。

其中，轻量级 YOLO-LNet 模型作为教师模型，剪枝后的小模型作为学生模型。此时，特征蒸馏过程中的损失包括两个方面：学生模型的预测输出与真实标签之间的误差损失以及学生模型与教师模型产生的预测输出之间的损失。所以当学生模型的预测输出与教师模型的预测输出相同时，便可以认为教师模型将“知识”传递给学生模型。

图 4-5 是特征蒸馏的结构示意图。在特征蒸馏的过程中，需要关注的另一个关键点是：学生模型的通道数量应与教师模型的通道数量应保持一致，这样教师模型的知识才会有效的传递给学生模型。自 FitNets 首次将特征蒸馏的思想扩展到中间层表示，以提升学生模型的性能。其关键思想是让学生模型直接模仿教师模型的中间层特征，并由此提出了一系列间接方式以对齐教师和学生之间的特征，如注意力图、Gramian 矩阵和成对相似性方法等。这些方法通常依赖于传统特征工程中的先验知识，并且对原始特征进行转换时会丢失信息。因此在本节中为了使得学生模型和教师模型的通道对齐，采用归一化特征蒸馏方法，旨在通过蒸馏过程中的归一化来去除特征响应的大小。




图 4-5 特征蒸馏模型的结构示意图

在特征蒸馏模型的设计中，本论文主要关注“教师-学生模型间的特征损失”、“标签损失和定位框损失”。

对于特征蒸馏损失，通过在蒸馏过程中使用归一化的方法来去除特征响应中幅值的大小。通常是在 BN 层、线性层中计算特征的均值和方差对特征进行不同维度的归一化操作，以去除原始特征的幅度信息。

具体做法如下：首先，对教师和学生的特征进行归一化，通过使其具有零均值和单位方差来去除其幅值信息。然后，最小化教师与学生归一化特征之间的损失，如公式（4-2）所示：

$$L_{fd} = D(\text{Norm}(F_t), \text{Norm}(F_s)) \quad (4-2)$$

其中， $F_t$  和  $F_s$  分别是学生和教师的特征， $D$  表示  $L_2$  距离， $\text{Norm}$  表示归一化操作，其具体操作如公式（4-3）所示：

$$\hat{F} = \frac{1}{\delta}(F - \mu) \quad (4-3)$$

其中， $F$  是原始特征， $\hat{F}$  是归一化特征， $\mu$  和  $\delta$  分别是均值和标准差。

通过使用归一化特征蒸馏损失，可以避免原始蒸馏损失中教师-学生模型内部特征的强制对齐操作。另外，该方法与原始的特征蒸馏相比，学生模型更加侧重于学习教师模型特征的分布规律，以达到更高的相似性，而并非简单模仿特征相应的幅值。

对于标签损失，采用自适应调节蒸馏温度的方法。其理论依据如下：

首先，定义锐度  $S_T$  表示教师模型第  $i$  类输出结果的离散程度，如公式（4-4）所示：

$$S_T = \log \sum_i e^{TP_i/T_T} \quad (4-4)$$

其中， $TP_i$  表示教师模型第  $i$  类的输出结果；

定义锐度  $S_s$  表示学生模型第  $i$  类输出结果的离散程度，如公式（4-5）所示：

$$S_s = \log \sum_i e^{SP_i/T_s} \quad (4-5)$$

其中， $SP_i$  表示学生模型第  $i$  类的输出结果；

使用  $G_{T-S}$  衡量教师模型和学生模型输出结果之间的差距，其泰勒展开式如公式（4-6）所示：

$$\begin{aligned} G_{T-S} &= \log \sum_i e^{TP_i/T_T} - \log \sum_i e^{SP_i/T_s} \\ &\approx \log \left( k + \frac{1}{T_T} \sum_i TP_i + \frac{1}{2T_T^2} \sum_i TP_i^2 \right) - \log \left( k + \frac{1}{T_s} \sum_i SP_i + \frac{1}{2T_s^2} \sum_i SP_i^2 \right) \end{aligned} \quad (4-6)$$

其中， $k$  表示第  $i$  类的图像样本数量；

由 logits 函数可知：  $\sum_i TP_i = \sum_i SP_i = 0$ ， $G_{T-S}$  可表示为公式（4-7）：

$$\begin{aligned}
 G_{T-S} &= \log \left( k + \frac{1}{2T_T^2} \sum_i TP_i^2 \right) - \log \left( k + \frac{1}{2T_S^2} \sum_i SP_i^2 \right) \\
 &= \log \left( 1 + \frac{1}{2T_T^2 k} \sum_i TP_i^2 \right) - \log \left( 1 + \frac{1}{2T_S^2 k} \sum_i SP_i^2 \right)
 \end{aligned} \tag{4-7}$$

其中,  $\frac{1}{k} \sum_i TP_i^2$  是教师模型输出结果的方差, 用  $std_T^2$  表示;  $\frac{1}{k} \sum_i SP_i^2$  是学生模型输出结果的方差, 用  $std_S^2$  表示;

$G_{T-S}$  可进一步表示如公式 (4-8) 所示:

$$G_{T-S} = \log \left[ 1 + \frac{1}{2} (std_T/T_T)^2 \right] - \log \left[ 1 + \frac{1}{2} (std_S/T_S)^2 \right] \tag{4-8}$$

令  $G_{T-S} = 0$ , 确定教师模型蒸馏温度  $T_T$  和学生模型蒸馏温度  $T_S$  之间的关系, 即  $std_T/T_T = std_S/T_S$ ;

最终, 只需初始化教师模型的蒸馏温度便可实现自适应标签蒸馏, 以实现教师-学生标签间的动态平衡。

在自适应标签蒸馏过程中, 利用具有蒸馏温度  $T_T$  的激活函数 **Softmax** 对教师模型第  $i$  类第  $j$  个样本的输出结果  $TP_{ij}$  进行激活操作, 如公式 (4-9) 确定  $T_{ij}$ :

$$T_{ij} = \frac{e^{TP_{ij}/T_T}}{\sum_j e^{TP_{ij}/T_T}} \tag{4-9}$$

利用具有蒸馏温度  $T_S$  的激活函数 **Softmax** 对学生模型第  $i$  类第  $j$  个样本的输出结果  $SP_{ij}$  进行激活操作, 如公式 (4-10) 确定  $S_{ij}$ :

$$S_{ij} = \frac{e^{SP_{ij}/T_S}}{\sum_j e^{SP_{ij}/T_S}} \tag{4-10}$$

自适应蒸馏损失函数  $L_{AD}$  如公式 (4-11) 所示:

$$L_{AD} = -\sum_{i,j} T_{ij} \log S_{ij} \tag{4-11}$$

学生模型的损失函数  $L_S$  如公式 (4-12) 所示:

$$L_S = -\sum_{i,j} y_{ij} \log S_{ij} \tag{4-12}$$

其中,  $y_{ij}$  表示第  $i$  类第  $j$  个样本的真实标签值;

总损失函数  $L_{total}$  如公式 (4-13) 所示:

$$L_{total} = \lambda L_{AD} + (1 - \lambda) L_S \tag{4-13}$$

其中,  $\lambda$  表示权重因子;

对于定位框损失，采用均方误差损失，表示预测值与真实值之差的平方的平均值。如公式（4-14）所示：

$$MSE = \frac{1}{n} \sum_{n=1}^n (f(x_i) - y_i)^2 \quad (4-14)$$

其中， $n$  表示样本数量， $f(x_i)$  是真实值， $y_i$  是预测值。

因此，在本小节中将按照上述损失函数的设计进行设置，保证蒸馏之后的学生模型具备和教师模型相当的精度，甚至优于教师模型。

### 4.3 超轻量化 YOLO-ULNet 模型的验证

通道剪枝的结果如表 4-1 所示，其中 YOLO-CLNet 表示对 YOLO-LNet 进行通道剪枝后得到的网络。YOLO-CLNet 在计算机上的 mAP@0.5、速度、计算量和参数量分别为 64.9%、115FPS、0.4GFLOPs 和 0.19M。优于 YOLO-LNet 的计算量（0.7GFLOPs）、参数量（0.26M）、速度（110FPS）和模型大小（0.87MB）。结果表明，YOLO-CLNet 的速度提高 4.5%，这表明通道剪枝提高了速度，计算量减少了 42.86%，参数量下降了 24.32%。

表 4-1 通道剪枝前后模型性能对比

| 模型         | mAP@0.5<br>(%) | 计算量<br>(GFLOPs) | 参数量<br>(M) | 速度 (FPS) | 模型大小<br>(MB) |
|------------|----------------|-----------------|------------|----------|--------------|
| YOLO-LNet  | 71.2           | 0.7             | 261489     | 110      | 0.87         |
| YOLO-CLNet | 64.9           | 0.4             | 197893     | 115      | 0.72         |

由于使用通道剪枝后得到的 YOLO-CLNet 模型的准确率 mAP@0.5 相较于 YOLO-LNet 模型的准确率 mAP@0.5 下降了 6.3%。因此，使用特征蒸馏技术，不仅可以进一步压缩模型大小，而且还可以提升学生模型的准确率，有利于将 YOLO-LNet 模型部署在移动嵌入式设备上。

为了说明通道剪枝后 YOLO-CLNet 模型的有效性，将该模型部署到无人机上验证其检测精度和检测速度，测试结果表明，检测精度和检测速度分别为 64.9% 和 20.43FPS。如图 4-6 所示是 YOLO-CLNet 模型的检测精度和检测速度测试结果，(a) 图是无人机上的检测结果，(b) 图是检测结果窗口的数据，其中 ID 表示帧数，Size 表示图片的大小，Object 表示检测到的目标数，Time 表示推理时间，最后一行显示了检测速度，包含预处理、推理和 NMS 三项操作的总时间。




图 4-6 YOLO-CLNet 模型的检测结果。(a)检测效果, (b)推理结果

特征蒸馏的结果如表 4-2 所示, 其中 YOLO-DLNet 表示对 YOLO-CLNet 进行特征蒸馏后得到的模型。YOLO-DLNet 在计算机上的  $mAP@0.5$ 、计算量、参数量、速度和模型大小分别为 69.1%、0.4GFLOPS、0.19M、115FPS 和 0.63MB。优于 YOLO-CLNet 的  $mAP@0.5$  (64.9%) 和模型大小 (0.72MB)。结果表明, YOLO-ULNet 的  $mAP@0.5$  提高了 4.2%, 这说明特征蒸馏可以提高模型精度。


表 4-2 特征蒸馏前后模型性能对比

| 模型         | $mAP@0.5$<br>(%) | 计算量<br>(GFLOPs) | 参数量<br>(M) | 速度 (FPS) | 模型大小<br>(MB) |
|------------|------------------|-----------------|------------|----------|--------------|
| YOLO-LNet  | 71.2             | 0.7             | 261489     | 110      | 0.87         |
| YOLO-DLNet | 69.1             | 0.4             | 197893     | 115      | 0.63         |

从表 4-2 中可以得到, 进行特征蒸馏后, 检测的准确率  $mAP@0.5$  相比于通道剪枝提升了 4.2%, 达到了 69.1%, 模型大小减少了 27.6%, 仅为 0.63MB。究其原因主要有以下三个方面, 其一是通道剪枝通过多余的通道, 显著减少了模型的参数量和计算量; 其二是教师模型输出的“软标签”包含了大量隐性信息, 允许学生模型从这些隐性信息中学习彼此之间的内在联系, 进一步提高了数据理解和泛化能力; 最后, 为了进一步降低模型的计算量和存储空间, 采用模型量化技术将模型权重中使用 32 位表示的浮点数转换为了 8 位整数。

为了说明特征蒸馏后 YOLO-DLNet 模型的有效性, 将该模型部署到无人机上验证其检测精度和检测速度, 测试结果表明, 检测精度和检测速度分别为 69.1% 和 19.27FPS。如图 4-7 所示是 YOLO-DLNet 模型的检测精度和检测速度测试结果, (a) 图是无人机上的检测结果, (b) 图是检测结果窗口的数据, 其中 ID 表示帧

数, Size 表示图片的大小, Object 表示检测到的目标数, Time 表示推理时间, 最后一行显示了检测速度, 包含预处理、推理和 NMS 三项操作的总时间。



(a)

| ID                                                                                        | Size    | Object            | Time   |
|-------------------------------------------------------------------------------------------|---------|-------------------|--------|
| 291                                                                                       | 320×320 | 3 fires, 3 smokes | 0.051s |
| 292                                                                                       | 320×320 | 3 fires, 3 smokes | 0.042s |
| 293                                                                                       | 320×320 | 3 fires, 3 smokes | 0.057s |
| 294                                                                                       | 320×320 | 3 fires, 3 smokes | 0.044s |
| 295                                                                                       | 320×320 | 3 fires, 3 smokes | 0.039s |
| 296                                                                                       | 320×320 | 3 fires, 3 smokes | 0.040s |
| 297                                                                                       | 320×320 | 3 fires, 3 smokes | 0.045s |
| 298                                                                                       | 320×320 | 3 fires, 3 smokes | 0.048s |
| 299                                                                                       | 320×320 | 3 fires, 3 smokes | 0.040s |
| Speed: 3.9ms pre-process, 43.4ms inference, 4.7ms NMS per image at shape (1, 3, 320, 320) |         |                   |        |

(b)

图 4-7 YOLO-ULNet 模型的检测结果。(a)检测效果, (b)推理结果

## 4.4 超轻量化 YOLO-ULNet 模型的部署

### 4.4.1 int8 量化

模型量化是一种通过将模型中参数用更少的位数进行表示的方式来减少模型大小和计算负担的方法。通常情况下, 在深度学习模型中, 参数的存储通常是采用 32 位浮点数表示的, 但在实际工程应用中, 可以将这些参数用更少的位数表示 (如 8 位), 并可以保证不影响模型的预测精度。因此, 量化技术可以极大程度上减少模型需要的存储空间和计算资源, 因此, 本节中采用 int8 量化的方式部署该模型。

具体地, 本节采用阿里开发的边缘计算推理引擎 MNN, 对训练后的模型权重进行 int8 量化。这个过程实际上是将原本使用 32 位浮点数表示的激活值或权重近似为 8 位整数, 从而在更低位数的表示下进行计算。给定浮点类型的值, 可以通过公式 4-2 将它转化为 8bit 量化值:

$$\hat{x} = [\text{clamp}(x/s, Q_{\min}, Q_{\max})] \quad (4-15)$$

其中,  $s$  表示量化的 scale,  $Q_{\min}$  与  $Q_{\max}$  分别表示量化值域的最小值与最大值,  $x$  表示输入浮点值,  $\hat{x}$  表示量化后的值。

进一步地, 在将输入数据和权重进行量化后, 就能够将神经网络的常见操作转换为量化操作。以卷积操作为例, 其量化过程的计算流程如图 4-8 所示:






图 4-8 量化过程的计算流程图

首先将权重  $w$  与输入变量  $x$  转化为 8bit 整数做卷积运算，得到的中间结果  $\hat{y}_1$  用 32bit 整数保存；然后，再将  $\text{bias}$  量化为 32bit 整数，与  $\hat{y}_1$  进行相加得到  $\hat{y}_2$ ；接着利用  $x$ 、 $w$  以及  $y$  的量化  $\text{scale}$  将 32bit 的  $\hat{y}_2$  转化为 8bit 的  $\hat{y}_3$ ；最后，如果该层的下一层也是量化算子，则  $\hat{y}_3$  可直接输出给下一层；如果是非量化算子，则对  $\hat{y}_3$  进行反量化为浮点的操作后再输出给下一层。

表 4-3 是模型量化前后性能对比情况分析。

表 4-3 量化前后模型性能对比

| 模型         | mAP@0.5 (%) | 计算量 (GFLOPs) | 参数量 (M) | 速度 (FPS) | 模型大小 (MB) |
|------------|-------------|--------------|---------|----------|-----------|
| YOLO-LNet  | 71.2        | 0.7          | 261489  | 110      | 0.87      |
| YOLO-ULNet | 70.8        | 0.3          | 189756  | 121.6    | ...       |

通过  $\text{int8}$  量化后，FLOPs 下降了 57%，参数量下降了 4.11%，帧率达到了 121.6 帧，而  $\text{mAP}@0.5$  仅下降了 0.4%。图 4-9 展示了经过  $\text{int8}$  量化后得到的 YOLO-ULNet 模型在无人机端的检测速度。




图 4-9 YOLO-ULNet 模型在无人机端的检测速度



### 4.4.2 模型部署

模型部署平台采用树莓派 4B，如图 4-10 所示为树莓派 4B 的实物图。




图 4-10 树莓派 4B 实物图


硬件选型采用这款单板计算机，主要是由于其硬件是由 4 核主频为 1.5GHz 的 Broadcom BCM2711 芯片和 4GB LPDDR4 SDRAM 组成，芯片采用 ARM Cortex-A72 架构，使其具备处理一些轻量级的深度学习模型和机器学习算法的能力。其二，它尺寸小巧，体积仅为 85.6mm×56.5mm×17mm，便于搭载在无人机上。其三，树莓派 4B 的功耗较低，仅需 5V 3A 电源供电，适合长时间运行的应用场景。其四，它具有丰富的 GPIO 引脚和 USB 接口，可连接各种外围设备和传感器。其五，它具有 IEEE 802.11ac 无线局域网、蓝牙 5.0 和 Gigabit 以太网等多种通信方式，适用于远距离信息通信。因而选用树莓派 4B 作为模型部署中的硬件推理平台。

为了评估 YOLO-ULNet 在无人机平台上的检测性能，最终将该算法成功部署到了搭载树莓派 4B 的无人机上，用于森林山火视频流检测。具体的部署流程示意图如图 4-11 所示。



图 4-11 模型部署流程图

如 4-12 所示是推理回传的结果，图(a)是树莓派终端推理的检测画面，显示了推理时的速度为 24.57FPS，达到实时检测山火的目标。图(b)是推理终端回传的推理视频帧、画面大小、目标数量以及推理时间等信息。



(a)

| ID  | Size    | Object            | Time   |
|-----|---------|-------------------|--------|
| 291 | 320×320 | 3 fires, 3 smokes | 0.046s |
| 292 | 320×320 | 3 fires, 3 smokes | 0.037s |
| 293 | 320×320 | 3 fires, 3 smokes | 0.047s |
| 294 | 320×320 | 3 fires, 3 smokes | 0.042s |
| 295 | 320×320 | 3 fires, 3 smokes | 0.038s |
| 296 | 320×320 | 3 fires, 3 smokes | 0.040s |
| 297 | 320×320 | 3 fires, 3 smokes | 0.038s |
| 298 | 320×320 | 3 fires, 3 smokes | 0.042s |
| 299 | 320×320 | 3 fires, 3 smokes | 0.040s |

Speed: 3.3ms pre-process, 40.7ms inference, 4.1ms NMS per image at shape (1, 3, 320, 320)

(b)

图 4-12 推理回传结果

通过在无人机平台上部署，并对比不同模型的检测速度和置信度测试了模型的实际性能。如图 4-13 所示，分别展示了轻量化模型 YOLO-LNet 和超轻量化模型 YOLO-ULNet 在真实森林山火场景下的检测结果。由结果可知，轻量化 YOLO-LNet 模型的检测精度和检测速度分别为 77.75%和 14.39FPS。超轻量化 YOLO-ULNet 模型的检测精度和检测速度分别为 74.50%和 24.57FPS。经过模型压缩后获得的超轻量化 YOLO-ULNet 模型检测速度得到很大的提升。

通过在无人机端分别部署轻量化模型 YOLO-LNet 和超轻量化模型 YOLO-ULNet，可以发现经模型压缩后得到的超轻量化模型 YOLO-ULNet 在实际检测中表现更加出色，与轻量化模型 YOLO-LNet 相比，检测速度达到了 24.57FPS，实现了实时检测森林山火的功能，满足了实际场景下森林山火检测的需求。




图 4-13 不同轻量化模型在无人机上检测结果。(a)轻量化 YOLO-LNet 模型, (b)超轻量化 YOLO-ULNet 模型

## 4.5 本章小结

本章对超轻量化 YOLO-ULNet 模型的设计展开了研究, 并进行实验验证。首先, 对于超轻量化 YOLO-ULNet 模型进行设计, 采用了改进的通道剪枝技术, 获得了精简的模型; 并采用了改进的特征蒸馏技术, 获得了超轻量化 YOLO-ULNet 模型。然后, 从  $mAP@0.5$ 、速度、计算量和参数量对超轻量化 YOLO-ULNet 模型进行了验证。最后, 对超轻量化 YOLO-ULNet 模型进行部署, 并对其进行了 int8 量化。从检测精度和检测速度两个方面对超轻量化 YOLO-ULNet 模型在无人机上进行测试, 以验证超轻量化 YOLO-ULNet 模型的性能。

通道剪枝后 YOLO-CLNet 模型的实验结果表明, 该模型的  $mAP@0.5$ 、计算量、参数量、速度和模型大小分别为 64.9%、0.4GFLOPs、0.20M、115FPS 和 0.72MB, 优于 YOLO-LNet 的计算量 (0.7GFLOPs)、参数量 (0.26M)、速度 (110FPS) 和模型大小 (0.87MB)。结果表明, YOLO-CLNet 具有更低的计算复杂度、更少的参数量以及更小的存储需求。

特征蒸馏后 YOLO-DLNet 模型的实验结果表明, 该模型的  $mAP@0.5$ 、计算量、参数量、速度和模型大小分别为 69.1%、0.4GFLOPs、0.20M、115FPS 和 0.63MB, 优于 YOLO-LNet 的计算量 (0.7GFLOPs)、参数量 (0.26M)、速度 (110FPS) 和模型大小 (0.87MB)。结果表明, YOLO-CLNet 具有更低的计算复杂度、更少的参数量以及更小的存储需求。

int8 量化后 YOLO-ULNet 模型的实验结果表明, 该模型的  $mAP@0.5$ 、计算量、参数量和速度分别为 68.7%、0.3GFLOPs、0.19M、121.6FPS, 优于 YOLO-LNet 的计算量 (0.7GFLOPs)、参数量 (0.26M) 和速度 (110FPS)。结果表明, YOLO-CLNet 具有更低的计算复杂度、更少的参数量以及更快的检测速度。

最后, 将超轻量化 YOLO-ULNet 模型部署在无人机上的测试结果表明, 该模型的检测精度和检测速度分别为 74.50%和 24.57FPS, 达到了实时检测森林山火的目标。

综上, 超轻量化 YOLO-ULNet 模型部署在无人机上能够达到实时检测森林山火的目标。

## 第五章 总结与展望

### 5.1 研究工作总结

本文以在无人机上实现实时检测森林山火为研究目标，研究了轻量化目标检测设计方法，并设计了轻量化森林山火检测模型 YOLO-LNet。针对轻量化模型 YOLO-LNet 无法部署在无人机平台上，实现实时检测的问题，研究了通道剪枝、特征蒸馏、模型量化等深度学习模型压缩方法，利用这些方法获得了超轻量化森林山火检测模型 YOLO-ULNet，并成功部署在无人机平台上，实现实时检测森林山火的目标。本文的创新点总结如下：

#### （1）设计了轻量化 YOLO-LNet 模型

针对深度学习算法无法部署在算力低下的无人机上的难题，研究了轻量化神经网络设计方法，设计了 YOLO-LNet 模型用于检测森林山火。该模型主要由输入、骨干网络、颈部网络和输出头组成。其中，骨干网络由组通道重排单元组成的轻量级特征提取模块构建而成，以提取目标特征图并减少参数量；颈部网络采用部分卷积组成的轻量级特征融合（LEF）单元和改进的 C3\_LEF 单元组成的多路径聚合的特征金字塔结构，以融合不同维度的特征图并减少计算量。最后，设计了归一化 Wasserstein 距离的标签分配策略和损失函数，提高小目标的检测准确性。在 COCO 数据集上对 YOLO-LNet 进行了验证，结果表明该模型的计算量和参数量分别为 0.7GFLOPs、0.26M，mAP@0.5 为 37.2%，优于主流的轻量级 SOTA 算法 YOLOv5-Lite 的 35.1%，且只有 YOLOv5-Lite 参数量的 39.7%。此外，在无人机上使用 Fire-Smoke 数据集对 YOLO-LNet 进行了测试，结果表明该模型的检测精度和速度分别为 77.75%和 14.39FPS，仍无法满足实时检测要求。

#### （2）研究并设计了超轻量化 YOLO-ULNet 模型

针对 YOLO-LNet 实时性不足的问题，设计了超轻量化 YOLO-ULNet 模型。在通道剪枝方面，主要采用在 BN 层中施加  $L_1$  正则化方法筛选模型中的冗余通道，以提高检测速度。在特征蒸馏方面，主要采用归一化特征蒸馏方式对齐中间层特征，将教师网络 YOLO-LNet 中的特征传递到学生网络 YOLO-ULNet，以提高检测精度。量化方法则将权重为 32 位的浮点数转化为 8 位整数，进一步提高了检测速度。在无人机上使用 Fire-Smoke 数据集对 YOLO-ULNet 进行了测试，该模型的检测精度和速度分别为 74.50%和 24.57FPS，满足了实时性的要求。

## 5.2 展望

本文以无人机实时检测森林山火为研究目标，研究了轻量化目标检测设计方法，并设计了轻量化森林山火检测模型 YOLO-LNet。此外，研究了通道剪枝、特征蒸馏、模型量化等深度学习模型压缩方法，利用这些方法获得了超轻量化森林山火检测模型 YOLO-ULNet，并成功部署在无人机平台上，实现实时检测的目标。然而，在本文研究工作的基础上，仍有以下方向值得进一步研究：

（1）本论文中对烟雾的识别和定位仍存在着不准确的情况，通过对烟雾特性的进一步分析可知，烟雾是一种形态多变，缓慢移动的半透明物体。未来对烟雾的精确识别和定位，可以结合视频的前后时序信息对其进行识别，以达到精准识别和定位的能力。

（2）森林山火检测在不同场景下的泛化能力和准确率降低的问题。由于采用轻量化技术设计森林山火检测模型，必然会损失掉模型自身的非线性特征提取能力，导致其泛化能力和准确率下降。因此，在后续研究中，可探索更加高效的轻量化卷积算子和更加优秀的深度学习模型压缩方法，以提升超轻量化森林山火检测模型 YOLO-ULNet 的泛化能力和准确性。

（3）本文设计的超轻量化森林山火检测模型 YOLO-ULNet 在应对夜间检测和目标遮挡方面存在一定的缺陷。当夜间发生森林山火时，火焰作为目标对象是更容易检测到的，但由于环境光照的影响，会出现误识别的情况；另一方面，当森林植被茂密时，会出现严重遮挡目标的情况发生，导致检测能力下降。因此，在后续研究中，可探索与传感器结合的方式，相互补充，降低单一方法存在的局限性。



## 参考文献

- [1] Kadir E A, Alomainy A, Daud H, et al. Multi Sensor Network System for Early Detection and Prediction of Forest Fires in Southeast Asia[C]. The 2023 33rd International Telecommunication Networks and Applications Conference, Melbourne, Australia, 2023: 190-195.
- [2] Verstockt S, Vanoosthuyse A, Van Hoecke S, et al. Multi-sensor Fire Detection by Fusing Visual and Non-visual Flame Features[M]. Lecture Notes in Computer Science, Image and Signal Processing. 2010: 333-341.
- [3] Molina-Pico A, Cuesta-Frau D, Araujo A, et al. Forest Monitoring and Wildland Early Fire Detection by a Hierarchical Wireless Sensor Network[J]. 2016: 1-8.
- [4] Abdullah S, Bertalan S, Masar S, et al. A wireless sensor network for early forest fire detection and monitoring as a decision factor in the context of a complex integrated emergency response system[C]. The 2017 IEEE Workshop on Environmental, Energy, and Structural Monitoring Systems (EESMS), Milan, Italy, 2017: 1-5.
- [5] Bouabdellah K, Noureddine H, Larbi S. Using Wireless Sensor Networks for Reliable Forest Fires Detection[J]. 2013: 794-801.
- [6] Xu G, Zhong X. Real-time wildfire detection and tracking in Australia using geostationary satellite: Himawari-8[J]. 2017: 1052-61.
- [7] Leblon B, San-Miguel-Ayanz J, Bourgeau-Chavez L, et al. 3 - Remote Sensing of Wildfires[M]. Land Surface Remote Sensing. Elsevier. 2016: 55-95.
- [8] Allison R S, Johnston J M, Craig G, et al. Airborne Optical and Thermal Remote Sensing for Wildfire Detection and Monitoring[J]. 2016, 16(8): 1310.
- [9] Coen J L, Schroeder W. Use of spatially refined satellite remote sensing fire detection data to initialize and evaluate coupled weather - wildfire growth model simulations[J]. 2013, 40(20): 5536-41.
- [10] Rashkovetsky D, Mauracher F, Langer M, et al. Wildfire Detection From Multisensor Satellite Imagery Using Deep Semantic Segmentation[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 7001-16.
- [11] Cruz H, Eckert M, Meneses J, et al. Efficient Forest Fire Detection Index for Application in Unmanned Aerial Systems (UASs)[J]. 2016, 16(6): 893.

- [12] Yuan C, Liu Z, Zhang Y. Fire detection using infrared images for UAV-based forest fire surveillance[C]. The 2017 International Conference on Unmanned Aircraft Systems (ICUAS), Miami, FL, USA, 2017: 567-572.
- [13] Athans N, Themistocleous M, Kalabokidis K, et al. Big Data Analysis in UAV Surveillance for Wildfire Prevention and Management[M]. Information Systems, Lecture Notes in Business Information Processing. 2019: 47-58.
- [14] Dang-Ngoc H, Nuyen-Trung H. Evaluation of Forest Fire Detection Model using Video captured by UAVs[C]. The 2019 19th International Symposium on Communications and Information Technologies (ISCIT), Ho Chi Minh City, Vietnam, 2019: 513-518.
- [15] Yuan C, Liu Z, Zhang Y. Vision-based forest fire detection in aerial images for firefighting using UAVs[C]. The 2016 International Conference on Unmanned Aircraft Systems (ICUAS), Arlington, VA, USA, 2016: 1200-1205.
- [16] Jiao Z, Zhang Y, Mu L, et al. A YOLOv3-based Learning Strategy for Real-time UAV-based Forest Fire Detection[C]. The 2020 Chinese Control And Decision Conference (CCDC), Hefei, China, 2020: 4963-4967.
- [17] Jiao Z, Zhang Y, Xin J, et al. A Deep Learning Based Forest Fire Detection Approach Using UAV and YOLOv3[C]. The 2019 1st International Conference on Industrial Artificial Intelligence (IAI), Shenyang, China, 2019: 1-5.
- [18] Chen Y, Zhang Y, Xin J, et al. UAV Image-based Forest Fire Detection Approach Using Convolutional Neural Network[C]. The 2019 14th IEEE Conference on Industrial Electronics and Applications (ICIEA), Xi'an, China, 2019: 2118-2123.
- [19] Song K, Zhang Y, LU B, et al. UAV Forest Fire Detection based on RepVGG-YOLOv5[C]. The 2022 IEEE International Conference on Robotics and Biomimetics (ROBIO), Jinghong, China, 2022: 1277-1282.
- [20] Jia X, Wang Y, Chen T. Forest Fire Detection and Recognition Using YOLOv8 Algorithms from UAVs Images[C]. The 2023 IEEE 5th International Conference on Power, Intelligent Computing and Systems (ICPICS), Shenyang, China, 2023: 646-651.
- [21] Zhang Q-X, Lin G-H, Zhang Y-M, et al. Wildland Forest Fire Smoke Detection Based on Faster R-CNN using Synthetic Smoke Images[J]. Procedia Engineering, 2018, 211: 441-446.
- [22] Xie F, Huang Z. Aerial Forest Fire Detection based on Transfer Learning and Improved Faster RCNN[C]. The 2023 IEEE 3rd International Conference on Information Technology, Big Data and Artificial Intelligence (ICIBA), Chongqing, China, 2023: 1132-1136.



- [23] Chandana V S, Vasavi S. Autonomous drones based forest surveillance using Faster R-CNN[C]. The 2022 International Conference on Electronics and Renewable Systems (ICEARS), Tuticorin, India, 2022: 1718-1723.
- [24] Zhan Z, Xin C. Research on Forest Fire Detection Algorithm Based on Yolov5[C]. The 2021 International Conference on Intelligent Computing, Automation and Systems (ICICAS), Chongqing, China, 2021: 354-357.
- [25] Li W, Sun J, Chen Z, et al. Smoke and Flame Identification Method for the Entire Process of Grassland Fire Based on YOLOv5m-D and Static and Dynamic Characteristics[J]. IEEE Access, 2023, 11: 145536-50.
- [26] Wang T, Cao R, Wang L. FE-YOLO: An Efficient and Lightweight Feature-Enhanced Fire Detection Method[C]. The 2022 3rd International Conference on Electronics, Communications and Information Technology (CECIT), Sanya, China, 2022: 253-258.
- [27] Chen T-H, Wu P-H, Chiou Y-C. An early fire-detection method based on image processing[Z]. 2004 International Conference on Image Processing, 2004 ICIP '04. Singapore. 2005.10.1109/icip.2004.1421401
- [28] Yuan C, Liu Z, Zhang Y. UAV-based forest fire detection and tracking using image processing techniques[C]. The International Conference on Unmanned Aircraft Systems, Denver, CO, USA, 2015: 639-643.
- [29] Mahmoud M A I, Ren H. Forest Fire Detection Using a Rule-Based Image Processing Algorithm and Temporal Variation[J]. Mathematical Problems in Engineering. 2018: 1-8.
- [30] 李钢, 袁非牛, 夏雪, 等. 改进局部三值模式的烟雾识别和纹理分类[J]. 计算机科学与探索. 2020, 14(7): 11.
- [31] 韦海成, 王生营, 许亚杰, 等. 样本熵融合聚类算法的森林火灾图像识别研究[J]. 电子测量与仪器学报. 2020, 34(1): 171-7.
- [32] Giwa O, Benkrid A. A new flame-based colour space for efficient fire detection[J]. IET Image Processing. 2023: 1229-1244.
- [33] Barmoutis P, Dimitropoulos K, Kaza K, et al. Fire Detection from Images Using Faster R-CNN and Multidimensional Texture Analysis[Z]. ICASSP 2019 - 2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Brighton, United Kingdom. 2019.10.1109/icassp.2019.8682647
- [34] Zhang L, Wang M, Ding Y, et al. MS-FRCNN: A Multi-Scale Faster RCNN Model for Small Target Forest Fire Detection[J]. Forests 2023, 2023, 14(3): 616.

- [35] Li J, Tang H, Li X, et al. LEF-YOLO: a lightweight method for intelligent detection of four extreme wildfires based on the YOLO framework[J]. International Journal of Wildland Fire, 2023.
- [36] Al-Smadi Y, Alauthman M, Al-Qerem A, et al. Early Wildfire Smoke Detection Using Different YOLO Models[J]. Machines 2023, 2023, 11(2): 246.
- [37] Zeng L, Xu G, Dong L, et al. Fast smoke and flame detection based on lightweight deep neural network[Z]. 2020 12th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC). Hangzhou, China. 2020.10.1109/ihmsc49165.2020.00058.
- [38] Wang S, Chen T, Lv X, et al. Forest Fire Detection Based on Lightweight Yolo[C]. The 2021 33rd Chinese Control and Decision Conference (CCDC), Kunming, China, 2021: 1560-1565.
- [39] Fan R, Pei M. Lightweight Forest Fire Detection Based on Deep Learning[Z]. 2021 IEEE 31st International Workshop on Machine Learning for Signal Processing (MLSP). Gold Coast, Australia. 2021.10.1109/mlsp52302.2021.9596409
- [40] Ye J, Ioannou S, Nikolaou P, et al. CNN based Real-time Forest Fire Detection System for Low-power Embedded Devices[J]. 2023 31st Mediterranean Conference on Control and Automation (MED), Limassol, Cyprus, 2023: 137-143,
- [41] Qadir Z, Saeed N, Xiao Z, et al. FL-YOLOv7: A Lightweight Small Object Detection Algorithm in Forest Fire Detection[J]. Forests 2023, 14, 1812.
- [42] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[Z]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA. 2016.10.1109/cvpr.2016.91
- [43] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[Z]. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI. 2017.10.1109/cvpr.2017.690
- [44] Redmon J, Farhadi A. YOLOv3: An Incremental Improvement[J]. Computer Vision and Pattern Recognition, 2018.
- [45] Bochkovskiy A, Wang C-Y, Liao H-Y. YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. Cornell University - arXiv, Cornell University - arXiv, 2020.
- [46] Li C, Li L, Jiang H, et al. YOLOv6: A Single-Stage Object Detection Framework for Industrial Applications[J]. 2022.

- [47] Wang C-Y, Bochkovskiy A, Liao H-Y. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[J]. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023: 7464-7475.
- [48] Han S, Pool J, Tran J, et al. Learning both Weights and Connections for Efficient Neural Networks[J]. Neural and Evolutionary Computing, 2015.
- [49] Gao S, Huang F, Cai W, et al. Network Pruning via Performance Maximization[Z]. 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA. 2021.10.1109/cvpr46437.2021.00915
- [50] Liu Z, Li J, Shen Z, et al. Learning Efficient Convolutional Networks through Network Slimming[Z]. 2017 IEEE International Conference on Computer Vision (ICCV). Venice. 2017.10.1109/iccv.2017.298.
- [51] Ding X, Hao T, Tan J, et al. Lossless CNN Channel Pruning via Decoupling Remembering and Forgetting[J]. 2020.
- [52] Heo B, Kim J, Yun S, et al. A Comprehensive Overhaul of Feature Distillation[Z]. 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South). 2019.10.1109/iccv.2019.00201.
- [53] Liu T, Yang X, Chen C. Normalized Feature Distillation for Semantic Segmentation[J]. 2022.
- [54] Zhu K, He Y-Y, Wu J, et al. Quantized Feature Distillation for Network Quantization[J]. AAAI Conference on Artificial Intelligence, 2023.
- [55] Nagel M, Baalen M V, BLANKEVOORT T, et al. Data-Free Quantization Through Weight Equalization and Bias Correction[Z]. 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South). 2019.10.1109/iccv.2019.00141.
- [56] Ma N, Zhang X, Zheng H-T, et al. ShuffleNet V2: Practical Guidelines for Efficient CNN Architecture Design[M]. Computer Vision – ECCV 2018, Lecture Notes in Computer Science. 2018: 122-38.
- [57] Wang J, Chen K, Xu R, et al. CARAFE: Content-Aware ReAssembly of FEatures[Z]. 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South). 2019.10.1109/iccv.2019.00310
- [58] WANG J, XU C, YANG W, et al. A Normalized Gaussian Wasserstein Distance for Tiny Object Detection[J]. 2021.
- [59] Devries T, Taylor G. Improved Regularization of Convolutional Neural Networks with Cutout[J]. Cornell University - arXiv, Cornell University - arXiv, 2017.

- [60] Yun S, Han D, Oh S, et al. CutMix: Regularization Strategy to Train Strong Classifiers with Localizable Features -Supplementary Material[J]. 2019 IEEE/CVF International Conference on Computer Vision (ICCV), Seoul, Korea (South), 2019: 6022-6031.
- [61] Zhang H, Cisse M, Dauphin Y, et al. mixup: Beyond Empirical Risk Minimization[J]. Cornell University - arXiv, Learning, 2017.
- [62] He K, Sun J, Tang X. Single Image Haze Removal Using Dark Channel Prior[J]. IEEE Trans Pattern Anal Mach Intell, 2011, 33: 2341-53.
- [63] Chattopadhyay A, Sarkar A, Howlader P, et al. Grad-CAM++: Improved Visual Explanations for Deep Convolutional Networks[Z]. 2018 IEEE Winter Conference on Applications of Computer Vision (WACV). Lake Tahoe, NV. 2018.10.1109/wacv.2018.00097