

胡宇

在校生 | 大模型应用开发工程师

现居：浙江省 湖州市

电话：15682170212

生日：1999-02-12

邮箱：cosmoshy@163.com



教育背景 / Education

2017.09 - 2021.06 中南林业科技大学 机械设计制造及自动化 / 本科

平均学分绩点：3.66/5 综测排名：3/182

优秀毕业生、国家励志奖学金、连续三年奖学金、校级三好学生、优秀共青团员

2021.07 - 2023.03 深圳市雷迪奥视觉技术有限公司 结构工程师

负责地砖 BM 系列产品

2024.09 - 2027.06 电子科技大学 电子信息 / 硕士

平均学分绩点：3.82/5

专业技能 / Skills

大模型应用与 RAG 开发：熟练使用 LangChain 构建 RAG 核心链路；熟练使用 LangChain (LCEL) 构建自动化数据管道；掌握 RecursiveCharacter 文本切分、向量化重排及 Prompt 工程。

后端架构与高并发优化：熟练使用 FastAPI 异步框架，具备多进程部署经验；掌握 SSE(Server-Sent Events)流式通信技术，显著优化大模型推理响应延迟。

数据管理与持久化：熟悉 ChromaDB 向量库集成及 Top-K 语义检索；掌握 SQLite 会话持久化与 MD5 文件去重算法，具备高并发场景下的数据一致性与多用户隔离处理能力。

模型 API 与性能优化：熟悉大模型 API 接入，掌握流式输出 (Streaming) 技术与前端渲染，有效优化响应性能。

其它：熟悉 Linux 相关操作、熟悉 git 使用；深入研究 RGB-T 双模态目标检测算法 (课题)

项目经历 / Experience

项目名称：基于大模型的异步高并发智能客服问答系统(RAG)

技术栈：Python, FastAPI, LangChain, ChromaDB, SQLite, Streamlit

项目简介：从零独立设计并落地了一套前后端解耦的检索增强生成 (RAG) 系统。系统具备高并发抗压能力、多用户状态隔离机制以及增量知识库管理功能，可为 C 端用户提供毫秒级响应的流式问答服务。

核心工作：

- 架构演进与高并发：**基于 FastAPI 打造前后端解耦架构，利用底层线程池异步调度 LangChain LCEL 链路，剥离大模型 I/O 阻塞，结合 Uvicorn 多进程实现高并发吞吐。
- 会话隔离与持久化：**引入 SQLite 持久化会话状态，基于 Session ID 实现多租户上下文严格隔离，彻底解决高并发下的读写冲突与“串话”风险。
- 数据管道与增量查重：**设计离线知识入库管道，集成 chardet 自动处理乱码；基于 MD5 的增量查重机制，精准拦截重复文件，有效降低 Chroma 库冗余与 API 计费成本。
- SSE 流式极致交互：**基于 Server-Sent Events (SSE)协议，前端实时解析并渲染后端推理分片，实现平滑“打字机”效果，将首字响应时间 (TTFT) 压缩至百毫秒级。

竞赛奖项 / Assessment

第九届湖南省大学生机械创新设计大赛优胜奖

IEEE Xtreme19.0 全球极限编程大赛 排名：2216/8169